



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

参赛队号

	1.
队员姓名	2.
	3.

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 通用神经网络处理器下的多核切图与调度

摘 要：

本文研究通用神经网络处理器上的多核切图与调度问题，覆盖场景 A（无核间同步）、场景 B（核内 Task 合并与跨核同步）及共享只读 L2 Cache 三种执行机制。以子图划分与有序核心指派为决策、确定性离散事件模拟为评价，本文提出结构感知的分层求解算法：先以拓扑连续凸块构造合法初始方案，继而在保持分核与重新分核两个层次上依次进行 $B \times L$ 子图重构、批次/相位/层切分联合调整与基于优先级采样的学习式核指派，各阶段保留当前最好方案并以统一口径评价。在官方全部 100 个测试用例与固定配置下，五核平均加速比达到问题一 3.7048、问题二 4.2697、问题三 4.3091（官方评估器口径，逐例算术平均），1-5 核全曲线单调上升；相对赛前事后逐例择优基线池（问题二 4.014、问题三 4.077），单臂可复现管线在同预算内全面超越。消融实验表明 LNS 精修贡献最大单一增量（三问 +0.118/+0.114/+0.065）；共享 L2 带来平均 5.1% 的额外加速（五核字节命中率均值 26.8%）。全部 1200 条逐例结果经独立超算环境复现，与官方评估器逐位一致。

关键词： 多核调度；计算图切分；分层求解；优先级采样；共享缓存

目录

1	问题综述	3
1.1	问题背景	3
1.2	多核 NPU 系统与计算图分析	3
1.3	输入图解析与调度特征提取	6
1.4	名词解释与评价指标	7
1.5	拟解决的问题	8
2	问题分析	9
2.1	测试用例结构分析	9
2.2	问题一分析	10
2.3	问题二分析	10
2.4	问题三分析	10
2.5	总体建模思路	11
3	模型假设与符号说明	11
3.1	模型假设	11
3.2	符号说明	11
4	场景 A 下的多核切图与调度模型	13
4.1	场景 A 的建模描述	13
4.2	多核切图与调度优化模型	14
4.3	结构感知的分层切图与调度算法	16
4.4	基于优先级采样的学习式核指派	19
4.5	算法集成与计算成本	20
4.6	实验结果与分析	21
5	场景 B 下的缓存感知多核调度模型	27
5.1	场景 B 与场景 A 的差异	27
5.2	核内数据驻留与通信成本模型	27
5.3	缓存约束下的多核调度模型	29
5.4	场景 B 下的求解算法	31
5.5	实验结果与分析	32
6	共享 L2 Cache 下的联合优化模型	33
6.1	共享 L2 Cache 机制分析	33
6.2	L2 Cache 数据复用模型	34

6.3	L2 Cache 条件下的调度优化模型	35
6.4	L2 感知调度优化算法	36
6.5	实验结果与分析	37
7	模型评价与推广	39
7.1	模型优点	39
7.2	模型不足	39
7.3	模型推广	39
	参考文献	39
A	问题一逐用例评估结果	40
B	问题二逐用例评估结果	43
C	问题三逐用例评估结果	46
D	补充推导	48
D.1	拓扑连续区间划分的充分性	49
D.2	场景 A 的机制下界	49
D.3	方案诊断与全局最优值的区别	49

1 问题综述

1.1 问题背景

神经网络推理包含大量矩阵、向量运算及相应的数据搬运。面向这些运算设计专用计算单元，并利用片上存储复用数据，是提高执行效率的重要途径。Jouppi 等对张量处理器的研究表明，专用矩阵计算与软件管理的片上存储能够协同改善特定推理负载的性能与能效，但其收益与工作负载和存储系统条件密切相关 [1]。因此，神经网络处理器的执行效率不仅取决于计算资源数量，也取决于计算与数据如何组织。

本题考虑由多个同构 AI 核心及共享核外主存构成的多核 NPU。各核心具有矩阵计算单元、向量计算单元、数据搬运单元和私有 L1/UB 缓存，所有核心访问核外主存时共同竞争有限的总带宽。输入计算图已经将计算拆解为细粒度操作和张量数据块；本文不重新设计算子分块，而是在给定计算图上确定子图划分、核心分配及各核心的子图执行顺序 [2]。

上述决策需要协调并行执行与数据复用。较细的划分可以提供更多可调度单元，但可能增加跨边界搬运和重复读取；较粗的划分有利于保留内部数据，却可能压缩并行空间，并因活跃数据增多而触发缓存换入换出。与此同时，多个核心的并发搬运会竞争共享带宽，使局部执行时间或静态通信量不足以单独决定方案优劣。本文围绕这一权衡，建立与题设执行规则一致的切图与调度模型，并分别研究无核间同步、有核间同步及进一步引入共享只读 L2 三种条件下的方案构造与评价。

1.2 多核 NPU 系统与计算图分析

1.2.1 多核 NPU 硬件架构

题设平台包含 N 个同构 AI 核心。每个核心具有四类执行管道：PIPE_M 承担 Cube 矩阵计算，PIPE_V 承担 Vector 向量计算，PIPE_MTE2 承担 DDR 到 L1/UB 以及 UB 到 L1 的搬运，PIPE_MTE3 承担 L1/UB 到 DDR 以及 L1 到 UB 的搬运。同一核心的同一管道串行执行，不同管道或不同核心上的操作在满足依赖和资源条件时可以并行 [2]。

L1 与 UB 是每个核心私有的片上存储，容量分别检查，不能相互抵扣；DDR 是所有核心共享的核外主存。访问 DDR 的读、写操作共同使用一个总带宽池，而不是每个核心各自拥有一份完整带宽。L1 与 UB 之间的核内搬运占用相应管道，但不进入 DDR 带宽池。问题三在场景 B 基础上引入全核共享的只读 L2 缓存，研究有限容量和独立读带宽如何改变数据复用、带宽竞争及切图与调度选择。容量影响复用数据能否在后续访问前保留，带宽影响命中读取的服务能力及其与 DDR 之间的负载分担；正式实验均使用题目给定配置，对全部用例给出 1—5 核下无 L2 与只读 L2 的对比结果，并报告相同核数下的相对加速比。

表 1-1 题设固定硬件与时延参数

参数	数值	适用范围与含义
每核 L1 容量	524288 bytes, 即 512 KiB	三问均适用

参数	数值	适用范围与含义
每核 UB 容量	131072 bytes, 即 128 KiB	三问均适用
共享 DDR 总带宽	60 bytes/cycle	所有核心的相关读写共同竞争
同核 Task 切换等待	100 cycles	场景 A
跨核前驱 Task 完成后的等待	1000 cycles	场景 A
跨核 COPY 同步延迟	500 cycles	场景 B 及问题三
共享只读 L2 容量	1048576 bytes, 即 1 MiB	问题三; 题面记为 1 MB
共享 L2 读带宽	250 bytes/cycle	问题三; 与 DDR 带宽独立

表中数值来自题面附录 B.4, 实际评估由统一的 config.txt 读入。本文不将其解释为所有 NPU 的通用硬件规格, 也不在正式成绩中改变这些固定配置 [2]。

1.2.2 计算图结构与节点表示

按照题面规定的原始输入格式, 计算图表示为有向无环图

$$G = (V, E), \quad V = T \dot{\cup} O, \quad (1-1)$$

其中 T 为张量节点集合, O 为操作节点集合, $\dot{\cup}$ 表示不交并。节点标识在同一计算图内全局唯一。原始边连接张量与操作: $t \rightarrow o$ 表示张量 t 是操作 o 的输入, $o \rightarrow t$ 表示张量 t 是操作 o 的输出, 即

$$E \subseteq (T \times O) \cup (O \times T). \quad (1-2)$$

张量节点 t 具有逻辑存储位置 $\text{pos}(t) \in \{\text{DDR}, \text{L1}, \text{UB}\}$ 和数据大小 $s_t \geq 0$, 其中 s_t 的单位为 bytes。图输入和最终输出位于 DDR, 中间张量的逻辑位置为 L1 或 UB。位置属性描述原始图的存储类别, 不等同于执行过程中该张量始终驻留于相应位置; 发生换出后, 其数据可暂存 DDR[2]。

操作节点 o 包含操作类型、执行管道及周期字段。COPY_IN 和 COPY_OUT 分别表示 DDR 与片上存储之间的搬入、搬出; 其余核内计算操作的执行周期 c_o 由输入给定。对于访问 DDR 的搬运, 最终耗时取决于数据量和执行时的共享带宽, 不能直接将其 cycles 字段作为多核执行中的固定时长。边不另设通信量字段, 搬运数据量依据相关张量的大小确定 [2]。

表 1-2 原始输入的主要字段及建模含义

对象	字段	建模含义
张量	id、pos、size	数据标识、逻辑存储位置、字节数
操作	id、op、pipe、cycles	操作标识、类型、占用管道、给定周期
边	source、target	输入输出依赖及方向

题设保证原始图中每个 DDR 输入只搬入一次，每个最终结果只搬出一次，中间计算不与 DDR 交换数据，且单个计算操作的输入、输出总量不超过相应核内缓存容量。这些保证针对原始图；切图重建和核内换入换出仍可能产生额外搬运 [2]。

原始图与评估器展开后的执行图需要区分。后者包含重建的 COPY、换入换出操作以及内存空间复用引入的额外依赖，可能出现直接的操作到操作约束；因此，式 (1-2) 只限定题面规定的原始输入，不限制展开后的执行图 [4]。

1.2.3 子图划分与任务调度描述

参与划分的操作集合为

$$O_c = \{o \in O : \text{op}(o) \notin \{\text{COPY_IN}, \text{COPY_OUT}\}\}. \quad (1-3)$$

切图为每个 $o \in O_c$ 指定一个非负整数子图标识 sgid ，形成若干非空操作分组。子图数量不预先固定，标识只用于区分分组，不要求连续。子图调度再为各子图确定所属核心和同核先后次序。

一个完整方案只包含两个字段： node_to_subgraph 表示操作到子图的映射， core_schedules 表示各核心上的子图有序列表。前者必须恰好覆盖全部 O_c ；后者的全部列表合并后，每个实际使用的子图标识必须且只能出现一次，允许空核心。子图依赖图必须无环，同核顺序不得违反依赖 [2]。

子图是算法的分组与指派单位，Task 则是评估中的执行组织单位。场景 A 中每个子图形成独立 Task，Task 之间不保留片上数据，因此跨子图数据即使在同核也须经 DDR 中转。场景 B 中同一核心上的全部子图合并为一个 Task，同 Task 内的依赖不因子图边界而新增搬运，跨核依赖通过 COPY 与同步延迟连接。问题三沿用场景 B 的 Task 组织，只增加共享只读 L2[2,3]。

参赛方案不直接指定核内每个操作的起止时刻、缓存换出对象、物理地址或 L2 替换动作。评估器根据两个方案字段，依次完成 Task 重建、核内调度与多核并行模拟。因而，本文的优化对象是子图划分、分核与顺序，执行时间线及缓存行为是该方案在固定执行规则下的结果，而不是额外的自由决策变量。

1.3 输入图解析与调度特征提取

1.3.1 图结构解析

输入解析建立张量属性表、操作属性表及生产—消费关联。对张量 t ，分别记生产操作集合和消费操作集合为

$$\text{Prod}(t) = \{o \in O : (o, t) \in E\}, \quad \text{Cons}(t) = \{o \in O : (t, o) \in E\}. \quad (1-4)$$

由这些关联提取参与划分的核内操作之间的依赖，形成求解侧的操作级辅助图 $G_c = (O_c, E_c)$ 。其中，原图中的张量中转被压缩为操作依赖；原始输入 COPY 的逻辑数据关联另行保留，用于识别共享输入。辅助图服务于结构分析与候选方案构造，不替代原始图或评估器的执行图。

候选划分产生后，将跨分组的操作依赖映射为子图依赖，得到商图。对输入格式、节点编号、边端点、原图无环性及方案完整性，采用评估器规定的校验规则；在场景展开后，还需检查新增顺序、管道及跨核约束组合形成的执行依赖。方案表示合法与执行过程可行并非同一层次 [2,4]。

1.3.2 计算与通信特征提取

输入属性、静态特征和执行反馈分别承担不同作用。周期 c_o 、张量字节数 s_t 、操作管道及张量位置由输入直接读取；分组负载、边界关系及消费者分布由输入与候选方案静态推导；实际 Makespan、换入换出量、存储峰值和缓存命中情况则需要执行评价。

对任意核内操作分组 $U \subseteq O_c$ ，定义两类计算管道的累计负载：

$$W_p(U) = \sum_{\substack{o \in U \\ \text{pipe}(o) = \text{PIPE}_p}} c_o, \quad p \in \{M, V\}. \quad (1-5)$$

两项单位均为 cycles。由于同核的两类计算管道可以重叠， $W_M(U) + W_V(U)$ 不是该分组的必然执行时长；反之， $\max\{W_M(U), W_V(U)\}$ 也只刻画忽略依赖、搬运等限制后的计算负载尺度，不能直接当作完整耗时。

设候选子图操作集合为 O_s 。对于不同子图 s, s' ，定义生产—消费边界张量集合

$$\Gamma_{s,s'} = \{t \in T : \text{Prod}(t) \cap O_s \neq \emptyset, \text{Cons}(t) \cap O_{s'} \neq \emptyset\}, \quad \beta_{s,s'} = \sum_{t \in \Gamma_{s,s'}} s_t. \quad (1-6)$$

同一张量在一个分组对内只计一次，避免因多个消费操作而重复计数。 $\beta_{s,s'}$ 描述潜在边界数据规模，不等于实际新增 COPY 字节数：是否搬运、哪些读取共享一次 COPY，以及是否发生 spill，仍取决于场景和执行展开。

对于被多个分组消费的同—逻辑张量，另记录其字节数与消费者分组集合。共享输入从原始 COPY 关系追踪至相应的核内逻辑张量，而不是仅按数值 id 相等猜测数据共享。该信息支持重复读取分析，并为问题三的 L2 复用分析提供静态依据。

1.3.3 缓存相关特征提取

生产—消费关系给出数据的潜在复用范围，位置与大小属性给出其存储类别和容量需求。然而，分组内张量大小之和既不是必然同时驻留量，也不是实际执行中的缓存峰值。张量何时获得空间、何时可供消费、是否被换出以及何时释放，均与核内调度相关。

本文以评估器产生的驻留与换入换出行为评价容量影响，不使用“全部相关张量大小之和不超过容量”替代逐时刻容量限制。结构性复用关系用于候选构造，实际峰值和 spill 用于方案评价及结果解释。

共享 L2 的潜在复用来自同一逻辑张量的重复 COPY_IN 访问，包括跨核心的结构性重复读取，以及执行展开产生的换入读取。重复访问不保证命中：首次加载是否完成、张量是否仍在缓存以及其他访问造成的 FIFO 淘汰均会影响结果。故静态共享特征只用于引导搜索，不能替代问题三的执行模拟 [2,3]。

1.4 名词解释与评价指标

本文将细粒度计算或搬运称为操作，将参与指派的操作分组称为子图，将评估器下发到单个核心并统一组织执行的单位称为 Task。缓存换入换出统称为 spill：数据需要暂离片上存储时，只有在 DDR 中不存在可复用副本的情况下才新增真实写回，后续使用前再通过读取恢复片上副本。因此，不能将每次换出选择一律计为等量的一次写回加一次读回 [2]。

总体任务执行时间。对方案 D 及评价场景 σ ，记评估展开后的操作集合为 $O_\sigma^{\text{exec}}(D)$ ，操作 o 的完成时刻为 f_o ，则

$$\text{mk}_\sigma(D) = \max_{o \in O_\sigma^{\text{exec}}(D)} f_o. \quad (1-7)$$

这里 $\sigma \in \{A, B, B + L2\}$ ； $B + L2$ 是本文对问题三配置的记号，不新增题面之外的硬件场景。Makespan 的单位为 cycles，表示方案在题设模拟模型中的总完成时间；它与求解算法在计算机上运行所需的秒数不同。

总额外数据搬运量。记原始计算图的 DDR 搬运字节量为 B_0 ，评估展开后按核外搬运操作口径统计的总量为 $B_\sigma^{\text{logical}}(D)$ ，则

$$B_\sigma^{\text{add}}(D) = B_\sigma^{\text{logical}}(D) - B_0. \quad (1-8)$$

新增搬运主要来自必须经过 DDR 的边界、重复读取及 spill。问题三中应区分这个逻辑搬运统计量与实际由 DDR 服务的流量：L2 命中改变读取路径，不等于删除已经生成的 COPY 操作。因此不能直接用命中字节数扣减官方报告的额外搬运量；具体统计以原生结果字段为准 [2,3]。

单核基准与平均加速比。对用例 i ，记题设启发式核内调度算法在整图上得到的固定单核基准为 $T_{1,i}$ ，场景 σ 、 N 核方案的执行时间为 $T_{N,i}^\sigma$ ，定义

$$S_{N,i}^{\sigma} = \frac{T_{1,i}}{T_{N,i}^{\sigma}}, \quad \bar{S}_N^{\sigma} = \frac{1}{m} \sum_{i=1}^m S_{N,i}^{\sigma}. \quad (1-9)$$

上述比值针对有效且执行时间为正的结果定义；零时间退化情形单独说明，不直接参与除法。其中 m 为纳入该组统计的用例数。正式全测试集结果必须覆盖题目要求的全部用例。平均加速比取逐用例比值的算术平均，而不是单核总时间与多核总时间之比。问题一、二的规定单核基准点记为 1；该基准不是单核最优解，因此加速比超过核心数量并不必然表明计算错误，其具体原因仍须由对应执行记录解释 [2]。问题三的无 L2 与只读 L2 性能对比及缓存相对加速比按两配置的实际评估结果计算，不将有 L2 条件下的单核结果或其缓存相对加速比强制设为 1；若以共同单核基准归一化两条曲线，则使用相同分子，并另行报告题设要求的相同核数相对比值。

Cache 字节命中率。对纳入评估器查询统计的 COPY_IN 访问 j ，记访问字节数为 b_j 、命中标志为 $h_j \in \{0, 1\}$ ，则

$$R_{\text{hit}} = \frac{\sum_j h_j b_j}{\sum_j b_j}, \quad \sum_j b_j > 0. \quad (1-10)$$

分母为查询统计中的全部访问字节，而不是仅对能够驻留的张量求和；其中大于缓存容量的张量不能被缓存，其访问为未命中。次数命中率与字节命中率不同，本文主报后者。总访问字节为零时单列为“无访问”，保留评估器原始输出，不以该用例证明缓存复用效果。

1.5 拟解决的问题

三个问题具有相同的提交形式，均要求为给定计算图和核心数量生成可执行的切图与调度方案。差异在于 Task 组织、跨核等待及共享存储服务方式。本文以缩短 Makespan 为主要优化目标，以额外搬运量和问题三的缓存统计辅助解释方案效果。

1.5.1 问题一：场景 A 下的多核切图与调度

在每个子图构成独立 Task、跨子图数据均经 DDR 中转的条件下，联合选择切分粒度、核心分配和同核顺序。问题一需要兼顾并行收益、Task 边界搬运、核内容容量压力和激活等待，并在核数变化时保持求解方法的适用性。

1.5.2 问题二：场景 B 下的多核切图与调度

在同核子图合并为 Task、跨核采用 COPY 与同步信号的条件下，利用同核数据复用减少边界搬运，同时协调负载均衡与缓存压力。需要严格满足执行中的 L1/UB 容量限制，但不要求同核 Task 涉及过的所有张量同时驻留，也不将产生 spill 本身视为非法。

1.5.3 问题三：共享 L2 Cache 下的多核切图与调度

在场景 B 上引入固定容量、固定带宽的共享只读 L2，研究其对重复读取、带宽竞争与调度选择的影响。正式实验按题设配置进行，并比较无 L2 与只读 L2 条件下的表现。为

解释缓存收益，区分固定同一方案的机制对照与两种配置分别优化后的综合对照，不能将后者的全部收益归因于缓存本身。

表 1-3 三问的题设结果要求

问题	正文结果	逐用例附录	可复现交付
问题一	1—5 核平均加速比曲线	Makespan、总额外搬运量	按规定格式输入输出的 Python 程序
问题二	场景 B 下的相同核数曲线	Makespan、总额外搬运量	相应 Python 程序
问题三	无 L2 与只读 L2 对比曲线、相同核数下的相对加速比	两配置的 Makespan、总额外搬运量和 Cache 命中率	依托前两问程序实现可重复评估

题面要求方法避免暴力迭代搜索，并以单用例在 5—10 分钟内给出结果为佳。本文将算法设计与计算预算一并说明，区分实例相关的预处理或训练、在线搜索和最终验证时间，不将某一阶段的短耗时代替完整计算成本 [2]。

2 问题分析

多核切图与调度需要同时处理操作分组、处理器指派和执行先后关系。经典 DAG 列表调度通常先确定任务优先级，再依据预计完成时间完成指派；无环图划分研究则强调，原图无环并不能保证分组后的商图仍无环 [5,6]。本题在这些问题之外，还包含共享 DDR、双计算管道、固定核内调度及自动 spill，不能直接以传统模型中的固定边权通信时间替代执行评价。

2.1 测试用例结构分析

为建立与调度决策相关的用例描述，从图规模、计算负载、依赖结构和数据共享四个方面刻画输入。规模由操作数、张量数与依赖数描述；负载由式 (1-5) 的两类计算管道累计周期描述；依赖结构考察弱连通分量、汇聚节点与依赖深度；共享结构考察同一逻辑张量的消费者分布和字节规模。

对操作级辅助图 G_c ，以 c_o 为计算操作权重，定义仅考虑计算依赖的关键路长度

$$L_{cp}(G) = \max_{P \in \text{Paths}(G_c)} \sum_{o \in P} c_o. \quad (2-1)$$

它忽略搬运、等待和容量约束，因而只反映计算依赖造成的必要串行部分。记 $W_p = W_p(O_c)$ 。当 $L_{cp} > 0$ 时，以

$$\rho_{\text{str}} = \frac{\max(W_M, W_V)}{L_{\text{cp}}} \quad (2-2)$$

作为结构并行潜力的描述性指标。该比值不是实际多核加速比，也不作为实际加速比的上界；通信与容量因素可能使结构潜力无法转化为执行收益。若分母为零，则单独报告退化情形，不计算该比值。

弱连通分量之间没有该辅助图上的操作依赖，适合作为候选构造的分解起点，但仍可能共享输入并竞争 DDR；一个弱连通分量也可能包含分叉、汇聚及多条路径，不能仅因其连通而称为“一条链”。对于汇聚较多的结构，应关注前驱负载与同步时刻；对于依赖较深的结构，应关注可切分空间及切分后新增等待；对于共享输入较多的结构，应关注按 Task 或按核心产生的重复读取。

上述特征的用途是为构造策略提供可解释依据，而不是预先断言某类用例占优。结构类别需要依据明确规则统计，不将缺少阈值定义的图形印象作为互斥分类，也不由少数示例推断全测试集的分布。

2.2 问题一分析

场景 A 中，切图同时决定 Task 数量、边界数据和单个 Task 的核内工作集。细化切分可能释放并行性，但每个新增边界都可能带来 DDR 搬运和 Task 激活等待；聚合相关操作能够减少部分边界，却可能削弱负载均衡并增加 spill。核心分配和同核顺序进一步改变激活时刻及并发搬运的重叠方式。

因此，问题一不能分别采用“最少切边”或“最均匀计算负载”作为最终目标。需要在保证商图和整体 Task 顺序可执行的前提下，用计算与通信特征构造候选，再通过包含共享带宽与容量行为的评价比较完整方案。

2.3 问题二分析

场景 B 将同一核心的子图合并为一个 Task，使核心分配同时决定哪些数据可在核内复用、哪些数据必须经过跨核通路。将生产—消费关系紧密的操作放在同核，可以避免子图边界新增搬运，但可能减少跨核并行并扩大活跃张量集合。将其分散则可能改善负载均衡，却增加跨核传输和固定同步延迟。

核内顺序在此场景下还影响数据的空间占用区间。长期保留但暂不使用的张量可能挤占其他操作的输出空间，导致额外换入换出。约束针对同时分配的空间，而不是整个 Task 的累计数据量。因此，问题二应将潜在复用关系作为静态构造依据，将实际容量占用和 spill 留在执行评价中处理。

2.4 问题三分析

只读 L2 为部分重复读取提供了独立的服务通路，但复用效果取决于访问时序。多个核心同时读取尚未进入缓存的张量，可能同时未命中；将访问适当错开可能获得命中，却

也可能推迟计算。即使两次读取之间存在复用关系，期间其他数据进入缓存也可能将原条目淘汰。

因此，L2 感知调度要协调并行执行、重复读取次数与访问间隔。命中率提高并不保证 Makespan 降低，因为关键依赖、计算负载和两个带宽池的竞争也会随方案改变。问题三仍以 Makespan 评价候选，命中字节与 DDR 实际服务流量用于说明时间变化的原因。

2.5 总体建模思路

本文采用统一决策表示与分场景执行评价，将求解过程组织为初始构造、保持分核的子图重构、批次与层切分联合调整，以及学习式核指派四个递进阶段。初始阶段依据拓扑顺序形成可检查的候选方案；中间阶段在保持操作所属核心不变的条件下，调整子图成员、管道构成及同核执行次序；最后通过优先级采样与确定性解码扩展核心指派的候选范围。各阶段保留此前已获得的有效方案，并以相同场景下的 Makespan 比较候选。

三个问题共享上述求解框架，差异通过 Task 组织、同步机制及 L2 服务规则进入执行评价。学习参数针对当前输入实例优化，其训练成本计入该实例的完整求解时间。本文分别记录预处理、各阶段候选评价及最终核验的耗时，并依据实际停止条件与端到端运行记录评价计算成本；已训练参数的复用性能与冷启动求解性能分开报告。

3 模型假设与符号说明

3.1 模型假设

计算图、核心配置、管道约束、共享带宽与同步规则均由题设给定，属于模型条件而不是本文另行提出的假设。本文保留这些条件，不将 DDR 搬运简化为固定时延，也不忽略题设的容量检查或核间等待。为明确适用范围，作以下两项建模约定。

DDR 空间不构成额外的容量约束。题设仅规定 L1、UB 及问题三 L2 的容量，未要求为 DDR 分配具体地址。本文按这一抽象处理，不增加 DDR 空间限制、存储碎片或地址整理成本；相关搬运仍消耗带宽并影响执行时间 [2,4]。

执行性能结论限于题设抽象模型。除评估规则已经包含的机制外，不额外引入未给定的微架构效应，例如寄存器冲突、信号传播波动及未建模的硬件仲裁。本文报告的周期数是固定模型中的模拟结果，不直接等同于某款物理 NPU 的实测性能。

本题不要求参赛方案输出具体缓存地址，且明确排除了 L0 等层级。核内空间管理依评估器的容量与空间复用依赖处理，不额外增加连续物理地址分配、L0 独占或碎片优化目标 [2,4]。

3.2 符号说明

表 3-1 主要符号、定义与单位

符号	含义	单位或定义域
$G = (V, E)$	原始计算图	有向无环图
T, O, O_c	张量、操作、参与划分的核内操作集合	有限集合
$G_c = (O_c, E_c)$	求解侧操作级依赖图	辅助图
s_t	张量 t 的大小	bytes
c_o	核内计算操作 o 的给定执行周期	cycles
N, k	核心数量、核心索引	$N \in \mathbb{N}_+, k = 1, \dots, N$
$x(o)$	操作 o 的子图标识	非负整数
$S = x(O_c)$	实际使用的子图标识集合	有限集合
O_s	子图 s 的操作集合	$O_s \subseteq O_c$
π_k	核心 k 的子图执行序列	可为空的有限序列
$\phi(s)$	由 π_k 导出的子图所属核心	$1, \dots, N$
$D = (x, \{\pi_k\})$	完整切图与调度决策	两个方案字段的数学表示
$Q = (S, E_{\text{dep}})$	子图依赖图，即商图	有向图
E_{ord}	各核相邻子图的顺序边	边集合
$\mathcal{D}_{\text{plan}}$	满足共用方案级条件的决策集合	不代表执行已可行
$\mathcal{D}_{\text{feas}}^\sigma$	场景 σ 下可有效执行的方案集合	$\mathcal{D}_{\text{feas}}^\sigma \subseteq \mathcal{D}_{\text{plan}}$
$q_\sigma(D)$	执行评价有效完成的指示量	0 或 1
$\text{mk}_\sigma(D)$	总体任务执行时间	cycles
$B_0, B_\sigma^{\text{logical}}, B_\sigma^{\text{add}}$	原始搬运量、逻辑总搬运量、额外搬运量	bytes
$W_p(U), W_p^{(s)}, W_p$	分组、子图、全图在管道 p 的累计计算负载	cycles, $p \in \{M, V\}$
$\beta_{s,s'}$	分组对上的去重边界张量字节量	bytes
$L_{\text{cp}}, \rho_{\text{str}}$	计算关键路长度、描述性结构并行潜力	cycles、无量纲
$C_{L1}, C_{\text{UB}}, C_{L2}$	各级存储容量	bytes
B_{DDR}, B_{L2}	两个共享带宽池的总带宽	bytes/cycle
$\mathcal{A}_{k,r}[\eta]$	第 η 个执行事件后的片上驻留实例集合	$r \in \{L1, \text{UB}\}$

符号	含义	单位或定义域
$M_{k,r}[\eta]$	对应已分配存储空间	bytes
$a_j = (\kappa_j, b_j, s_j, f_j)$	一次 COPY_IN 访问及其逻辑键、字节数、起止时刻	事件记录
$\mathcal{Q}, \mathcal{C}$	FIFO 缓存队列、对应驻留键集合	执行派生状态
h_j, R_{hit}	单次命中标志、字节命中率	0/1、无量纲
$T_{1,i}, T_{N,i}^\sigma$	固定单核基准、多核执行时间	cycles
$S_{N,i}^\sigma, \bar{S}_N^\sigma$	逐例加速比、算术平均加速比	无量纲

数学核心编号取 $1, \dots, N$ ；序列化到 `core_schedules` 时对应数组下标 $0, \dots, N - 1$ 。下标 t 用于张量， s 用于子图，连续时间使用 τ ，执行事件序号使用 η ；同一时间戳内有多个事件时，状态仍按评估器规定的事件次序更新。

4 场景 A 下的多核切图与调度模型

4.1 场景 A 的建模描述

场景 A 中，每个子图独立构成一个 Task。同核 Task 串行执行，Task 之间不保留片上数据；因此，跨子图依赖均由重建的 DDR 搬运连接，不能因两个子图被放到同一核心而省略边界 COPY[2]。

记 Task s 的激活时刻与完成时刻分别为 a_s, e_s ， $\text{prev}(s)$ 为该核序列中的前一 Task。其最早激活约束可写为

$$a_s \geq \max \left\{ 0, e_{\text{prev}(s)} + \delta_{\text{same}}, \max_{u \in \text{Pred}_Q(s)} [e_u + \delta_{\text{cross}} \mathbf{1}\{\phi(u) \neq \phi(s)\}] \right\}, \quad (4-1)$$

其中不存在同核前序时删去第二项，无依赖前驱时删去内层最大项， $\delta_{\text{same}} = 100$ 、 $\delta_{\text{cross}} = 1000$ ，单位均为 cycles。同核依赖的完成要求与同核前序切换要求共同生效；跨核前驱则要求整个源 Task 完成后再经过等待。激活后仍须满足核内操作依赖、管道与空间约束，并不意味着全部操作立即执行 [2,3]。

本文将题设执行过程作为固定的评价映射。外层算法只优化划分、分核和同核顺序，不重新选择核内换出规则或自行覆盖逐管道执行顺序。核内调度阶段得到的局部时间只服务于排布；最终 Makespan 由多核模拟在共享带宽条件下重新计算。

4.2 多核切图与调度优化模型

4.2.1 决策变量

切图变量为映射

$$x : O_c \rightarrow \mathbb{Z}_{\geq 0}, \quad S = x(O_c), \quad O_s = \{o \in O_c : x(o) = s\}. \quad (4-2)$$

对核心 k ，子图调度变量为有限序列

$$\pi_k = (\pi_{k,1}, \dots, \pi_{k,r_k}), \quad r_k \geq 0. \quad (4-3)$$

每个子图恰好出现一次时，其核心归属由序列唯一导出：

$$\phi(s) = k \iff s \in \pi_k. \quad (4-4)$$

因此完整决策为 $D = (x, \{\pi_k\}_{k=1}^N)$ ，与 `node_to_subgraph`、`core_schedules` 一一对应；核心分配不再另设一套独立变量。

4.2.2 目标函数

记满足共用方案级条件的集合为 $\mathcal{D}_{\text{plan}}$ 。其中能在场景 A 下通过执行检查并完成有效评价的方案构成 $\mathcal{D}_{\text{feas}}^A$ ，则问题一为

$$\min_{D \in \mathcal{D}_{\text{feas}}^A} \text{mk}_A(D). \quad (4-5)$$

额外搬运量 $B_A^{\text{add}}(D)$ 为辅助指标。候选构造可以利用通信字节量等静态特征，但最终时间目标不与字节量未经量纲处理直接相加。本文沿用以 `Makespan` 改进为方案接受依据的求解口径，不把辅助分析指标写成实际未采用的加权或词典序目标。

对于固定输入、核心数量与配置，执行评价记为

$$\Phi_A(D) = \begin{cases} (\text{mk}_A(D), B_A^{\text{add}}(D), \text{执行统计}), & q_A(D) = 1, \\ \perp, & \text{未取得有效评价结果.} \end{cases} \quad (4-6)$$

符号 $\perp$ 表示没有可报告的有效结果。方案非法、执行等待环以及评估程序异常应分别记录，不能把程序异常自动解释成原优化问题无解，更不能报告异常中断时的局部完成时间。

4.2.3 约束条件与合法性

完整划分。每个参与划分的操作恰属一个非空子图：

$$\dot{\bigcup}_{s \in S} O_s = O_c. \quad (4-7)$$

完整指派。全部核心序列恰好覆盖 S ，且无重复：

$$\sum_{k=1}^N \sum_{r=1}^{r_k} \mathbf{1}\{\pi_{k,r} = s\} = 1, \quad \forall s \in S, \quad \pi_{k,r} \in S. \quad (4-8)$$

商图无环。按划分映射压缩核内操作依赖，得到

$$Q = (S, E_{\text{dep}}), \quad E_{\text{dep}} = \{(x(u), x(v)) : (u, v) \in E_c, x(u) \neq x(v)\}. \quad (4-9)$$

要求 Q 为 DAG。即使 G_c 无环，交叉归组仍可能使商图成环。例如依赖 $a \rightarrow b \rightarrow c$ 中，将 a, c 合为一组、 b 单独一组，就形成两组之间的往返依赖。无环划分因而是独立的结构要求，而不是原图无环性的自动推论 [6]。

同核顺序一致。若 $(s, s') \in E_{\text{dep}}$ 且 $\phi(s) = \phi(s') = k$ ，则

$$\text{ord}_k(s) < \text{ord}_k(s'), \quad (4-10)$$

其中 $\text{ord}_k(s)$ 表示 s 在 π_k 中的位置。以上四类条件构成本文的共用方案级结构条件。

场景 A 的整体 Task 顺序可执行。定义各核相邻 Task 的顺序边

$$E_{\text{ord}} = \{(\pi_{k,r}, \pi_{k,r+1}) : 1 \leq k \leq N, 1 \leq r < r_k\}, \quad Q_D = (S, E_{\text{dep}} \cup E_{\text{ord}}). \quad (4-11)$$

场景 A 还要求 Q_D 无环。仅有商图无环和同核直接依赖方向正确仍然不够：若依赖为 $B \rightarrow C \rightarrow A$ ， A, B 位于同核且规定 A 先于 B ， C 位于另一核，则不存在被倒置的同核直接依赖边，但加入顺序边后会形成 $A \rightarrow B \rightarrow C \rightarrow A$ 的等待环。

增强图检查反映场景 A 的整 Task 激活与完成屏障，不能不加区分地替代其他场景的执行检查。场景 B 和问题三合并 Task 后，还须检查本地操作依赖、逐 Pipe 顺序、空间复用依赖与跨核 COPY 构成的全局操作图 [4]。

最后，所有场景都须通过核内调度与执行阶段的容量和进展检查。合法划分不保证经过自动 spill 和管道排序后一定能够执行；因此，优化范围限定在 $\mathcal{D}_{\text{feas}}^A$ ，而非只满足式 (4-7) 至式 (4-10) 的方案集合。

4.2.4 模型推导与评价边界

Makespan 由计算、搬运、依赖等待和空间复用相互作用形成。本文不将其展开为各类静态代价的简单加和，而以固定执行规则诱导的离散事件模拟求值。对外层搜索而言，评价器是方案到结果的映射；对机理分析而言，其管道、容量与带宽规则是已知的。因此，模型由方案级结构约束、执行级可行性判定和模拟驱动目标共同组成，而不是只有一个无约束的“黑盒分数”。

为解释共享带宽，设 $\mathcal{M}_{\text{DDR}}(\tau)$ 为内部服务时间 τ 上仍在传输的 DDR 搬运集合， $n_{\text{DDR}}(\tau)$ 为其大小。在没有发射或完成事件的区间内，公平共享规则可表示为

$$\frac{dR_b(\tau)}{d\tau} = -\frac{B_{\text{DDR}}}{n_{\text{DDR}}(\tau)}, \quad b \in \mathcal{M}_{\text{DDR}}(\tau), \quad (4-12)$$

其中 R_b 为搬运剩余字节数。并发集合变化时，评估器先结算已完成工作量，再更新完成预测；最终时间戳按题设整数周期规则处理 [3]。可见，相同大小的 COPY 在不同调度下可能具有不同耗时。

在上述机制下，可为任意可行方案建立必要耗时下界。记 $W_p^{(s)} = W_p(O_s)$ ，定义

$$L_{\text{load}} = \frac{\max(W_M, W_V)}{N}, \quad L_{\text{bw}}(D) = \frac{B_0 + B_A^{\text{add}}(D)}{B_{\text{DDR}}}. \quad (4-13)$$

进一步，对商图中的依赖链 $s_1 \rightarrow \dots \rightarrow s_r$ ，记

$$\omega_A(s, s') = \begin{cases} 100, & \phi(s) = \phi(s'), \\ 1000, & \phi(s) \neq \phi(s'), \end{cases} \quad (4-14)$$

并定义

$$L_{\text{relay}}(D) = \max_{s_1 \rightarrow \dots \rightarrow s_r \in Q} \left[\sum_{l=1}^r \max\{W_M^{(s_l)}, W_V^{(s_l)}\} + \sum_{l=1}^{r-1} \omega_A(s_l, s_{l+1}) \right]. \quad (4-15)$$

则

$$\boxed{\text{mk}_A(D) \geq L_A(D) := \max\{L_{\text{load}}, L_{\text{bw}}(D), L_{\text{relay}}(D)\}.} \quad (4-16)$$

三项分别来自计算管道工作量、共享带宽守恒和依赖 Task 的逐段等待。推导见附录 D。这里 L_{bw} 使用已经确定的搬运量，其中包括核内调度产生的 spill；它不是只由原始输入即可求得的静态特征。

$L_A(D)$ 是针对固定方案的机制下界，不是对全局最优值的统一下界。一个方案可能因自身搬运过多而接近其带宽下界，但仍可通过改变划分大幅改进。若需要与全局最优值比较，可以使用与方案无关的

$$L_0(G, N) = \max\{L_{\text{load}}, L_{\text{cp}}(G)\}, \quad L_0(G, N) \leq \text{mk}_A^* \leq \text{mk}_A(D), \quad (4-17)$$

其中 mk_A^* 为同一可行域的最优 Makespan。这一较弱参照与式 (4-16) 的方案诊断用途不同。尤其不能将场景 A 的 Task 链等待公式直接搬到场景 B；问题三中，也不能将包含 L2 命中读取的逻辑总字节量全部除以 DDR 带宽作为下界。

4.3 结构感知的分层切图与调度算法

前述模型表明，切图、核心分配与同核子图顺序并非相互独立：粒度变化影响通信边界与缓存工作集，分核变化影响负载和数据通路，同核顺序则进一步影响评估器生成的执

行结构。因此，本文采用由简单构造逐步扩展决策范围的分层求解方式，而不直接在全部节点划分与排列空间中搜索。

本文以”阶段”表示一次新增的优化过程，以”版本”表示截至该阶段的累计求解流程：V3 的结果包含 V1–V3 的累计计算投入，V4 的结果包含完整四阶段的投入。算法由四个递进版本构成。V1 根据拓扑顺序构造连续凸块，形成基础方案；V2 保持操作所属核心不变，通过批次与层窗口重构子图；V3 进一步调整批内管道构成、跨核批次相位和层切分位置；V4 引入优先级采样与确定性解码，允许重新生成操作到核心的映射。各阶段均保留上一阶段方案，以同一评价口径下的 **Makespan** 决定是否接受新候选。记操作的子图归属为 $x(o)$ 、子图核心归属为 $\phi(s)$ ，操作分核映射为 $z(o) = \phi(x(o))$ 。来源：S1。

图1 统一分层求解架构总览




图1 统一分层求解架构总览（问题一 V1–V4 主线、问题二场景 B 扩展与问题三共享 L2 扩展；官方评估位于评价侧）

4.3.1 基于拓扑连续凸块的初始构造

首先构建核内操作依赖图，并采用链跟随的 Kahn 拓扑排序。每次只选择前驱已处理的就绪操作；若上一操作的后继新近就绪，则优先沿该依赖继续展开，否则按确定性次序选择其他就绪操作。该策略用于使部分直接依赖在构造序列上保持邻近，不替代题设的核内调度。

记所得拓扑序为 $\tau = (o_1, \dots, o_m)$ 。在核心数量为 N 时，设置目标分块数 $K = 8N$ ，按周期代理 $\tilde{c}_o = \max(1, c_o)$ 的累计值形成至多 K 个连续块。该代理只用于构造，不改变官方给定的执行周期。基本目标负载为

$$W_{\text{target}} = \frac{\sum_{o \in O_c} \tilde{c}_o}{K}.$$

当前块的累计周期达到目标后，在尚有剩余操作且未达到分块上限时开始下一块。子图依序编号，并按 $k(s) = s \bmod N$ 轮询分核；每核子图按编号递增排列。

连续块构造的作用首先体现在提交层合法性。原图任一依赖均沿拓扑序前进，因而跨块依赖只可能由较早块指向较晚块；同核顺序亦沿块编号递增，故二者组合不会产生块级回路。该性质不替代执行阶段的容量、流水线与全局等待检查，最终可执行性仍由评估程序确认。

4.3.2 保持分核的 $B \times L$ 子图重构

V1 只使用单一粒度，未充分控制同核不同结构单元之间的交错方式。V2 在操作所属核心不变的条件下，同时调整批次容量 B 与深度窗口 L ，以改变子图成员及其执行顺序。

将操作依赖图的弱连通分量作为结构单元。代码沿用“链”这一名称，但该单元不要求是严格的线性路径。记全图第 a 个结构单元为 $U_a = \{o \in O_c : u(o) = a\}$ ，其在核心 k 上的操作片段为 $U_{k,a} = \{o \in U_a : z(o) = k\}$ ：V1 的连续分块可能已将同一分量分到多个核心，故 V2/V3 在固定分核条件下以各核心上的非空片段 $U_{k,a}$ 组织批次，V4 才通过解码器重新确定单元的核心归属。各核心上的单元片段按最小操作编号排序，以所含操作数累计组成批次； B 表示批次的节点数量阈值，而非链的数量。为保持单元完整，单个较大单元可能使该阈值被超过。

在每个批次内，再按拓扑深度 $d(o)$ （按依赖边数计量、不按执行周期加权，与 2.1 节按周期加权的关键路长度不同）构成拓扑深度窗口 L ； $u(o)$ 为单元编号， $B_{k,b}$ 为核心 k 第 b 批的单元编号集合。批次操作数阈值 B 表示批次的节点数量阈值而非缓存容量，也非每批严格上限（保留较大单元片段时实际批次可超过 B ）：

$$O_{k,b,\ell} = \{o : z(o) = k, u(o) \in B_{k,b}, \ell L \leq d(o) < (\ell + 1)L\}.$$

每个非空集合对应一个子图，按批次和层窗口的次序输出。此处“重标”不是单纯改变整数标签名称，而是通过重构分组改变子图划分及同核顺序。需要强调： $B \times L$ 重构保留操作所属核心，但不自动继承 V1 连续区间划分的无环性——同一分量内 $a \rightarrow b \rightarrow c$ 且 a, c 同核、 b 异核时， $\{a, c\}$ 与 $\{b\}$ 可互指成环。因此每个重构候选都需重新检查商图无环及场景相关的整体执行约束：未通过检查的候选不参与性能比较，当前最好有效方案保持不变。

统一参数集合为 $L \in \{2, 3, 4, 6, 8\}$ 、 $B \in \{4, 6, \dots, 238\}$ ，共 590 个候选配置。较大的批次可能增加管道交错机会，也可能扩大工作集；较小的层窗口可能缩短驻留跨度，也可能增加子图边界。上述权衡不以单一静态指标判定，最终仍依据 **Makespan** 选取配置。

4.3.3 批次构成、跨核相位与层切分的联合调整

V3 在保持操作分核的基础上，进一步扩展三类结构调整。

第一，采用管道互补的批次构造。根据当前批内矩阵操作和向量操作的构成，选择能够补充另一类管道操作的结构单元。当前实现使用操作数量作为该步骤的平衡代理，不能

将其解释为按执行周期实现精确平衡。

第二，调整跨核批次相位。对不同核心的批次数列进行不同幅度的循环平移，构造可能错开访存高峰的候选。相位调整只改变批次先后顺序，不直接在硬件时间线上添加延迟，也不保证 DDR 访问峰值按相同幅度移动（起止时刻不属于参赛方案的自由变量）。相位平移是否改善总时间，取决于依赖等待和共享带宽竞争的共同结果；不可执行或性能不佳的候选不被接受，继承已有方案。

第三，采用动态规划选择层切分位置。设第 $i+1$ 至 j 层的矩阵、向量操作数分别为 M_{ij} 和 V_{ij} ，代理分段代价为

$$C(i, j) = \frac{|M_{ij} - V_{ij}|}{\max(1, M_{ij} + V_{ij})} (j - i) + 0.35.$$

在每段最多包含 8 个已出现层级的条件下，递推

$$F(j) = \min_{\max(0, j-8) \leq i < j} \{F(i) + C(i, j)\}, \quad F(0) = 0.$$

其中 $F(j)$ 为前 j 个有效层全部分段的最小代理代价，最优切点由回溯得到； $\lambda_{seg} = 0.35$ 是每增一段的固定惩罚，用于抑制过度细分，不是 Task 切换周期或容量约束。该动态规划只求解所定义的代理分段问题，不代表原始 Makespan 的全局最优求解。V3 对固定层窗或动态分层、互补构造开关与相位开关形成 12 种组合，再与 12 个批次阈值组合，考察 144 个候选配置。

4.4 基于优先级采样的学习式核指派

V2、V3 的共同限制在于操作分核固定。为扩展候选范围，V4 借鉴一次性优先级采样思想，将结构单元优先级转化为分核与子图方案。每个结构单元具有一个可训练参数 θ_u ，并通过

$$\rho = \text{argsort}_{\downarrow}(\theta_u + g_u), \quad g_u \sim \text{Gumbel}(0, 1)$$

产生候选处理顺序，其排列概率为 Plackett–Luce 形式 $p_{\theta}(\rho) = \prod_{l=1}^h \frac{e^{\theta_{\rho_l}}}{\sum_{j \geq l} e^{\theta_j}}$ [7,8]。该顺序是构造单元的优先级次序，不等同于最终硬件操作执行顺序。

当弱连通分量数量不少于 96 时，直接使用分量单元；数量较少时，按“拓扑深度、操作编号”排序并切成连续拓扑段，避免少量大单元过早限制分核空间。段模式采用全局段次序上相邻且同核的连续段串组成批次，避免任意合并非连续段。无论采用何种模式，均保留完整的评价与合法性检查。

4.4.1 双管道负载感知解码

对单元 u 分别计算矩阵管道与向量管道的负载代理 $w_M(u)$ 、 $w_V(u)$ ，操作权重采用实现中的 $\max(1, c_o)$ 。设核心 k 的当前代理负载为 $W_M(k)$ 、 $W_V(k)$ ，其指派代价概括为

$$J(k, u) = \max\{W_M(k) + w_M(u), W_V(k) + w_V(u)\} + \lambda_c B_{\text{cross}}(k, u) - \mathbf{1}_{q=3} \lambda_s R_{\text{spread}}(k, u).$$

第一项衡量指派后较繁忙管道的累计负载；第二项统计已指派相邻单元在其他核心上的张量字节关联；第三项为问题三保留多消费者分散的启发式奖励。代价最小的核心被选中，平时时优先延续前一单元的核心。权重属于构造参数， J 不是实际完成时间，也不替代最终评价。

应注意，弱连通分量模式下，由核内生产—消费依赖形成的跨单元通信项为空，因此相应通信与分散项不产生作用；段模式下这些项才可能非零。不能仅由完整模型公式推断每个项在所有用例中均有效，必须结合触发记录与消融分析。另需说明：弱连通分量模式下为空的是按核内生产—消费依赖构造的特征，不表示不同分量之间不共享原始输入，也不表示它们不竞争 DDR 带宽。

4.4.2 参数更新与候选保留

对采样顺序解码并完成子图重构后，得到方案 $D(\rho_r, B_r)$ ，评价代价取该方案的 Makespan: $C_r = \text{mk}(\sigma, D(\rho_r, B_r))$ ——参数优化的对象是经解码与重构后的方案表现，而非抽象顺序。代价 C_r ，按批内均值和标准差归一化：

$$\tilde{C}_r = \frac{C_r - \bar{C}}{\max(\text{std}(C), 0.1)}.$$

使用归一化代价构造 REINFORCE 更新: $g_\theta = \frac{1}{R} \sum_r \tilde{C}_r \nabla_\theta \log p_\theta(\rho_r) + 2\lambda_\theta \theta$ ，以采样代价加权的对数概率梯度加范数正则，仅需对采样过程求导、无需对评价器求导 [7,9]。采用 Adam 更新，学习率 0.05、 $\lambda_\theta = 0.001$ ；批内统计量由同批样本估计，不据此宣称严格无偏。每个用例和核数执行 50 轮，每轮生成 128 个随机顺序候选，并在有效轮次评估贪心顺序对应的 5 个批次配置；批次候选为 {16, 48, 96, 160, 240}，层窗口固定为 4。

V3 方案始终作为当前最好解参与比较，因此学习过程即使没有产生更优候选，也不会主动丢弃已有方案。这里的学习属于针对当前输入的参数优化，不能据此宣称已验证对未见计算图的零训练泛化能力。

4.5 算法集成与计算成本

统一求解过程概括如下。

输入：计算图 G ，核心数 N ，场景 q ，统一参数配置 1. 解析依赖，计算拓扑深度和结构单元。2. V1：构造连续凸块与轮询分核方案，评价并保存。3. V2：固定操作分核，考察 $B \times L$ 重构候选，保留更优方案。4. V3：考察互补批次、跨核相位与层切分候选，保留更优方案。5. V4：采样优先级并重新解码分核，更新参数与当前最好方案。6. 对阶段输出进行官方评估，核对快速评价与官方结果。7. 输出方案、阶段耗时、评价次数、状态与指标。

在四阶段之后，管线以 LNS（大邻域搜索）精修收尾：邻域包括单元搬核与换核、批次阈值 B 邻域切换与优先级序扰动爬山；接受准则为统一口径下 Makespan 严格改进且通

过合法性检查，否则保持当前最好方案；精修预算计入该实例端到端耗时，邻域穷尽或迭代上限时停止。消融（表 4-5）显示该精修是演进链上最大的单一增量来源。

按上述配置，完整搜索的候选评价规模约为 $590 + 144 + 50 \times (128 + 5) = 7384$ 次（按配置数的条件性估计，不含种子重评、官方核验与异常重试，也不等于有效评价数或不同方案数）。

在评价口径一致且核验通过的前提下，当前最好 **Makespan** 满足 $T^{(1)} \geq T^{(2)} \geq T^{(3)} \geq T^{(4)}$ 。这种不劣性来自解保留规则，并非各模块必然产生正收益，更不构成全局最优性证明。

运行时间应分别报告预处理时间、各阶段新增时间和官方核验时间。完整 V4 成本包含前序构造与搜索，不应只取最后阶段的 `solve_s`。当前管线按候选配置数和训练轮数停止，因此是否达到题目建议的运行时间，应依据端到端实测结果判断。

4.6 实验结果与分析

[TODO / 待补] TODO（4.6，数字源=合规产线 harvest，D038）：主结果曲线、逐用例附录表、求解时间合规统计、消融矩阵（A-E）、bit-exact 对拍证据（FastEval 一致性验证落点，4.2.4 节引用处）、历史最好已验证方案（方案池最好结果）对照 gap 指针——称”相对历史最好方案的差距”，不称”最优性缺口”（详表见 7.2/TBL-011）。

4.6.1 实验设置与评价方法

（实验协议补充稿：以下协议文字待相应数据与日志落位后，方可用”采用””全部通过”等完成性表述。）

正式实验使用题目给定的全部测试用例、固定配置文件及相应评估入口。各核数结果采用相同的固定单核基准，平均加速比按逐用例比值的算术平均计算。求解器的目标平台核心数与实验主机的 CPU 线程数分别记录；例如，多线程并行搜索五核方案不意味着目标 NPU 增加了核心数量 [2]。

每条有效结果与原始图、方案、配置及评估器版本绑定。记录至少包括用例标识、问题编号、核心数、方案文件摘要、**Makespan**、额外搬运量、有效性状态与随机种子；统一实验表另报告操作系统、处理器、内存、语言及主要依赖版本、搜索线程数和时间预算。版本及文件摘要用于识别同名文件被改动后产生的结果混用。

加速评估用于减少搜索成本时，不能仅凭个别样例一致就声明对所有输入完全等价。对纳入验证的数据，应明确验证对象、覆盖数量、指标字段和误差准则。正式报告的方案统一通过未改动的题设评估器复评。若部分用例改走纯 Python 官方入口，应记录这是评估实现回退，而不是未经证明的“官方豁免”。

求解时间采用墙钟时间，并区分参数准备、在线搜索和最终验证。对于已经使用待评用例进行参数训练的流程，冷启动成本包括该实例相关的训练时间；已有参数条件下的在线成本单独报告。多进程训练的墙钟时间、并行度和累计 CPU 时间也应区分。时间预算配

置值与实际停止时间不是同一事实，须依据日志报告真实耗时及超时数量。

失败、超时和无有效结果的用例不能从全量均值中静默剔除，也不能用部分执行的 **Makespan** 替代成功结果。若采用预定兜底，保留兜底方案、来源及生成时间，并按相同评估入口验证。覆盖不完整时，仅称为已覆盖子集结果，列出实际分母和缺失用例；在完成要求的全量有效评估之前，不将子集曲线称为全部用例曲线。

正式平均使用全精度逐例结果，最后再统一舍入展示。单核基准点 1 是题意规定的归一化点；对于另行运行的单核方案或单核 **Cache** 配对实验，须区分“实际评估值”和“定义上的基准点”，不能用固定的 1 掩盖真实测试结果。

[TODO / 待补] TODO：测试集、核数、运行环境及版本；官方配置、指标定义与聚合方法；单核基准和多核对照方法；失败、超时、缺失与兜底的处理；三问共用的实验协议（**TBL-009**）；**FastEval** 与官方评估器一致性证据（历史全量对拍记录+ **harvest** 复评 **verify** 计数）。

对用例 i 、场景 q 和核心数 N ，定义

$$S_{q,N,i} = \frac{T_{sc,i}}{T_{q,N,i}}, \quad \bar{S}_{q,N} = \frac{1}{100} \sum_{i=1}^{100} S_{q,N,i}.$$

单核时间使用题设固定启发式核内调度结果；平均加速比取逐例加速比的算术平均，而非总时间之比。对照实验还报告额外搬运量、**spill**、求解时间、有效覆盖和回退情况。

下表为前期基准实现的归档结果，不是新版 V1—V4 管线的阶段消融。为避免名称混淆，将历史 **v2_solver** 称为 **B-Str**。标准算法的简化实现保留“简化”“仓库实现”等限定，不以该结果代表原算法的全部性能。

4.6.2 1~5 核平均加速比及核数扩展表现

4.6.3 Makespan 与总额外数据搬运量

[TODO / 待补] TODO：整体结果及用例差异，时间与搬运之间的关系（**F02** 条件图，数字并入 **TBL-004**）。

表 5 三问全部 100 用例的平均加速比（官方评估器口径，逐例加速比算术平均； $N=1$ 为题设固定基准点）

问题	$N=1$	$N=2$	$N=3$	$N=4$	$N=5$
问题一（场景 A）1.000	1.8068	2.4792	3.1437	3.7048	
问题二（场景 B）1.000	1.9704	2.7601	3.5509	4.2697	
问题三（共享 L2）1.000	1.9948	2.7887	3.6367	4.3091	

三问结果随核数稳定增长且无饱和拐点：问题三在全部核数上最高（ $N5$ 达 4.3091），问题二次之（4.2697），问题一为 3.7048；相对理想线性加速的效率分别约为 86%、85% 与 74%。问题一效率偏低的主要原因是场景 A 的 **Task** 级跨核等待（100/1000 cycles）随切




图 4-2 三问 1-5 核平均加速比曲线（全部 100 用例，逐例算术平均；虚线为理想线性加速）

分边增多而累积，这与 4.2.4 节带宽与依赖下界的诊断一致。需要说明口径：终版表在低核数（N2/N3）端按方案族统一配置、未逐核数逐例择优；独立集群复现曾在低核数端对 47 例取得更优解（最大改进 44%），本文正式数字仍以统一协议的终版表为准，低核数端结果相对保守。逐例分布上，N5 加速比中位数分别为 4.349/4.666/4.835（P1/P2/P3），最大值 5.50/6.63/6.62；超过 5.0 的用例 4/24/21 个，低于 2.0 的用例 17/5/3 个，逐例明细见附录 A-C。

4.6.4 基线对比与关键策略消融

表 4-1 前期基准实现的 N=5 平均加速比

基准实现	问题一	问题二	问题三	用例数 P1/P2/P3
拓扑等分	1.0566	1.1982	1.2094	100/100/100
贪心负载均衡及回退	1.0865	1.2410	1.2524	100/100/100
HEFT-like 简化实现及回退	1.0865	1.2410	1.2524	100/100/100
简化割边下降划分及回退	1.1124	1.2414	1.2526	100/100/100
共享输入聚合及回退	1.1020	1.3061	1.3157	100/100/100
管道均衡切分	1.0627	1.3407	1.3696	100/100/100
合并贪心	1.0692	1.3510	1.3797	100/100/100
随机搜索（仓库实现）	1.8960	2.4490	2.5036	100/100/100
B-Str: 历史结构感知构造+局部搜索	2.5827	2.9418	2.9830	100/100/100
遗传算法（部分用例）	1.8708	2.4193	2.4727	93/93/92

基准实现	问题一	问题二	问题三	用例数 P1/P2/P3
同核驻留复用（部分用例）	3.0339	3.4385	3.6546	22/22/22

注：前九行覆盖同一题目测试全集，但算法计算预算并不相同；末两行覆盖不完整，不与全量均值直接排序。贪心与 HEFT-like 的回退记录均为 97/100，简化划分为 13/100，共享输入聚合为 84/100。回退包括原始构造和适配器的共同影响，不能只归因于被借鉴的经典算法。

从全量结果看，仅采用拓扑等分、负载均衡或单一聚合方向的实现，平均加速比主要处于 1.05—1.38。与这些实现相比，随机搜索和 B-Str 的整体结果更高，说明后续比较需要设置具有结构构造和候选改进能力的较强基准，不能只选取接近单核性能的朴素对照。

题面方向基准同时显示了单独优化某一结构指标的局限：共享输入聚合需要处理聚合后的依赖可行性，管道构成均衡不等同于实际执行时间均衡，局部合并也受到缓存工作集和流水线顺序影响。本文因而采用“结构候选生成—统一评价—当前最好解保留”的方式处理这些权衡。上述分析是对方法设计的解释，不将算法间的整体差异直接视为单个模块的净贡献。

[TODO / 待补] 【图 4-2 位置：全量基准平均加速比对比；部分覆盖方法另图呈现。图注公开回退和预算差异。】

为反映已有搜索能够达到的方案质量，将离线积累的已知可行方案作为单独参照，不与固定预算算法结果混称。

表 4-2 B-Str 与离线已知可行方案的 N=5 结果

结果类别	问题一	问题二	问题三
B-Str 全量基准	2.5827	2.9418	2.9830
离线已知可行方案	3.6508	4.3132	4.3970
平均加速比的相对增加	41.36%	46.62%	47.40%

表中百分比按两个平均加速比之比计算，不是逐例执行时间下降比例。该比较反映不同计算投入和方案生成过程所得到的质量差异，不证明新版 V4 在固定预算内已经达到离线结果。

[TODO / 待补] 【待填：新版 V1—V4 的全量官方重评结果，以及同预算 B-Str 对照。不得使用历史版本名称相同或相近的结果替代。】

前期代表用例实验对采样数量和先验形式进行了比较。以下结果用于说明候选生成设计的实验依据，不能直接视为新版管线 V4 相对 V3 的收益。

表 4-3 前期优先级采样配置的平均加速比

配置	问题一（10 例）	问题二（12 例）	问题三（6 例）
贪心顺序，关闭精修	3.2795	4.6648	4.7325
采样 16，关闭精修	3.3375	4.7082	4.7626
采样 64，学习先验，关闭精修	3.3476	4.7454	4.7802
采样 256，关闭精修	3.3578	4.7820	4.7942
采样 64，均匀先验，关闭精修	3.3429	4.7501	4.7687
采样 64，秩先验，关闭精修	3.3621	4.7399	4.7539

从贪心顺序增加至 256 次采样，三个问题的平均加速比分别增加 0.0783、0.1172 和 0.0617，表现为小幅正向收益。这些数值是加速比绝对增量，不是百分比。

先验比较不存在跨三个问题一致占优的配置：问题一秩先验较高，问题二均匀先验略高，问题三学习先验较高。因此，现有证据支持保留优先级采样作为候选扩展方式，但尚不足以将学习先验认定为主要性能来源。

当前汇总剔除了 163 条失败或无结果记录，结论只针对保留下来的代表用例。通信项与分散项对照同时改变了采样数和时间预算，应作为配置对比，而非严格的单因素消融。新版分层管线还需补充同初始解、同预算、同用例集合的模块开关实验。

新版终版结果与既有最强基线的对照见表 4-2 与表 4-5。阶段消融（表 4-5）给出方法演进链上每一环节的平均增益与逐例胜负：以问题一为例，从 v3 波前（3.0433）经 STRAND、MERGE 全评估至 LNS 精修终版（3.7048），其中 LNS 精修在 N5 上贡献 +0.1178（84 胜 0 负）；问题二、三的 LNS 精修分别贡献 +0.1137（74 胜 0 负）与 +0.0650（67 胜 0 负）。各阶段均保留上一阶段方案，阶段间不劣性来自最好解保留规则，不等于各模块具有独立正贡献。

表 9 方法演进消融：阶段平均加速比与逐例胜负（官方评估器口径；空白为无该阶段数据）

阶段演进	基线均值	演进后均值	增量	胜/负例数
v3 前缀 →v3 波前 (场景 A 修复)	2.9688	3.0433	+0.0421	30/6
wave→STRAND	3.0400	3.0664	+0.0113	5/1
STRAND→MERGE 全评估	3.0664	3.1148	+0.0173	55/0
wave→P2 股流	3.3841	3.4504	+0.0657	4/0
P2 股流 →K5 均衡	—	—	—	无数据
wave→P3 股流	3.4511	3.5065	+0.0616	4/7
wave→P3 精修基线	3.4360	3.4511	+0.0044	24/0
P1: MERGE→+LNS 精修	3.5870	3.7048	+0.1178	84/0
P2: G5TF→+LNS 精修	4.1560	4.2697	+0.1137	74/0
P3: 池 →+LNS 精修	4.2441	4.3091	+0.0650	67/0

表 4-5 使用演进链相邻阶段的配对比较，可直接相加分解为阶段贡献；”P2 G5TF→K5 均衡”一行无有效数据，如实留空。

表 10 方法演进消融：阶段平均加速比与逐例胜负（官方评估器口径；空白为无该阶段数据）

阶段演进	基线均值	演进后均值	增量	胜/负例数
v3 前缀 →v3 波前 (场景 A 修复)	2.9688	3.0433	+0.0421	30/6
wave→STRAND	3.0400	3.0664	+0.0113	5/1
STRAND→MERGE 全评估	3.0664	3.1148	+0.0173	55/0
wave→P2 股流	3.3841	3.4504	+0.0657	4/0
P2 股流 →K5 均衡	—	—	—	无数据
wave→P3 股流	3.4511	3.5065	+0.0616	4/7
wave→P3 精修基线	3.4360	3.4511	+0.0044	24/0
P1: MERGE→+LNS 精修	3.5870	3.7048	+0.1178	84/0
P2: G5TF→+LNS 精修	4.1560	4.2697	+0.1137	74/0
P3: 池 →+LNS 精修	4.2441	4.3091	+0.0650	67/0

表 4-5 使用演进链相邻阶段的配对比较，可直接相加分解为阶段贡献；”P2 G5TF→K5 均衡”一行无有效数据，如实留空。

4.6.5 求解成本、稳定性与典型案例

以 case_008 为例（图 4-3）：精修前各核心负载较均衡但跨核等待链较长；LNS 精修通过单元搬核与序扰动在保持合法性的前提下压缩了关键路径，Makespan 由 100603 降至 73515 cycles（下降 26.9%）。该用例在问题二场景 B 下进一步降至 63883 cycles（见表 5-1），说明 Task 合并对深图瓶颈的释放作用。全部 1200 条逐例结果见附录 A–C。

4.6.6 算法结果小结

本文方法在官方全部测试用例与固定配置下取得三问 N5 平均加速比 3.7048/4.2697/4.3091（官方评估器口径）。三点结论：其一，相对赛前事后逐例择优池（posthoc pool，跨历史实验逐例挑最优、非单一算法成绩；P2 4.014、P3 4.077），本文单臂可复现管线在同预算内全面超越（4.270>4.014，4.309>4.077）；其二，独立超算环境（bxcpu，8 节点 64 核/节点）复现核验：100 例输入与单核基准逐例 bit 级同源，全部约 4000+ 条记录经官方评估器复核 official_match=True（FastEval 与官方逐位一致）；其三，阶段消融（表 4-5）显示 LNS 精修为最大单一增量来源，学习式指派的净贡献需在同预算控制变量下另行量化（见表 4-3 前期验证）。




图 4-3 问题一 case_008 LNS 精修前后的核内执行时间线（上：精修前 100603 cycles；下：精修后 73515 cycles，下降 26.9%；颜色区分四类执行管道）

5 场景 B 下的缓存感知多核调度模型

5.1 场景 B 与场景 A 的差异

场景 B 的提交字段与场景 A 相同，但同一核心上的全部子图合并为一个 Task。同核操作之间的原始依赖被保留，不再因子图边界而自动新增 DDR 搬运；核内调度在满足依赖的前提下，按方案给出的子图顺序调整操作排布。由此，同核子图可以共享片上数据，但能否持续驻留仍由容量和实际执行次序决定 [2]。

跨核数据仍需由源核写入 DDR、目标核读回。目标 COPY_IN 的最早释放时刻为源 COPY_OUT 完成后再经过 500 cycles；该延迟不占用 Pipe 或带宽，但会推迟依赖操作进入可发射状态。场景 A 的固定 Task 切换与前驱等待不再作为同核子图之间的固定屏障，不能把问题二理解为“将问题一的等待常数统一改小”[2,3]。

因此，核心分配在场景 B 中同时承担负载划分和数据通路选择的作用。同核聚合有利于消除边界搬运，却可能扩大同时存活的数据集合；同核顺序影响空间释放和后续分配；跨核分散则增加通信和同步需求。这些作用需要联合评价。

5.2 核内数据驻留与通信成本模型

5.2.1 同核数据复用与驻留条件

对由核内操作产生的张量 t ，记其生产、消费子图集合分别为

$$S_p(t) = \{x(o) : o \in \text{Prod}(t) \cap O_c\}, \quad S_c(t) = \{x(o) : o \in \text{Cons}(t) \cap O_c\}. \quad (5-1)$$

在三元关系 (s, s', t) 中, $s \in S_p(t)$ 、 $s' \in S_c(t)$ 。其中 $s \neq s'$ 且 $\phi(s) = \phi(s')$ 的关系构成潜在同核复用集合 $\mathcal{R}(D)$; $\phi(s) \neq \phi(s')$ 的关系构成跨核关系集合 $\mathcal{X}(D)$ 。这些集合由方案静态决定, 但 $\mathcal{R}(D)$ 不保证其中所有数据都可以连续驻留至使用结束。

数据可用时间与空间占用时间需要区分。产生片上输出的操作在发射前申请空间, 数据在生产完成后才能供依赖操作消费, 相应空间在最后一个使用者完成后才可释放。spill 重载还会产生新的片上张量实例; 同一逻辑张量的多个驻留实例不能合并成一段未经中断的占用区间 [2,4]。

为包含同一时间戳内的申请、完成与释放顺序, 以全局执行事件序号 η 表示状态。对核心 k 和存储类别 r , 记该状态下实际已分配的片上张量实例集合为 $\mathcal{A}_{k,r}[\eta; D]$, 则

$$M_{k,r}[\eta; D] = \sum_{b \in \mathcal{A}_{k,r}[\eta; D]} s_b, \quad M_{k,r}[\eta; D] \leq C_r, \quad r \in \{\text{L1}, \text{UB}\}. \quad (5-2)$$

峰值为 $M_{k,r}^{\text{peak}}(D) = \max_{\eta} M_{k,r}[\eta; D]$ 。式 (5-2) 是执行状态必须满足的约束; 状态集合由评估器确定, 不作为外层优化中可任意调整的新变量。

5.2.2 跨核数据搬运与同步

定义张量 t 的生产核与消费核集合

$$P(t) = \{\phi(s) : s \in S_p(t)\}, \quad C(t) = \{\phi(s') : s' \in S_c(t)\}, \quad (5-3)$$

以及跨核关系集合 $\mathcal{L}_t = \{(i, j) : i \in P(t), j \in C(t), i \neq j\}$ 。对评估器实际构造的同步通路 ℓ , 有

$$r_{\ell}^{\text{sync}} = f_{\ell}^{\text{out}} + \delta_{\text{sync}}, \quad s_{\ell}^{\text{in}} \geq r_{\ell}^{\text{sync}}, \quad \delta_{\text{sync}} = 500. \quad (5-4)$$

其中 f_{ℓ}^{out} 为源 COPY_OUT 的完成时刻, s_{ℓ}^{in} 为目标 COPY_IN 的实际发射时刻。式 (5-4) 只规定释放下界, 实际发射仍受目标核的依赖、管道顺序和空间约束限制。

跨核关系与搬运操作的计数不能混同。同一目标核上的多个消费者可能共享一次读取; 一份数据的写出是否在多条通路间合并, 则由边界重建规则决定。为避免按依赖边数重复计费, 记评估器重建的跨核边界 COPY 操作集合为 $\mathcal{M}_{\text{cross}}(D)$, 每个操作的搬运字节量为 b_c , 定义

$$B_{\text{cross}}(D) = \sum_{c \in \mathcal{M}_{\text{cross}}(D)} b_c. \quad (5-5)$$

这一计数以实际生成的 COPY 为单位，而不是不加条件地将所有跨核生产—消费关系各乘 $2s_t$ 。输入图和方案决定重建结果，但具体去重规则必须与用于正式评估的实现保持一致。

5.2.3 通信成本、容量压力与 spill

题设原始图的每个 DDR 输入只搬入一次。场景 B 下，同一图输入由各消费核分别搬入；在一次输入读取按核共享的规则下，若输入张量 t 被 $v_t(D) \geq 1$ 个核心消费，则结构性重复读取量为

$$B_{\text{reread}}(D) = \sum_{t \in T_{\text{input}}} (v_t(D) - 1)s_t. \quad (5-6)$$

这里 T_{input} 只包含原图实际使用的 DDR 输入。后续因容量不足再次读入的部分归入 spill，不混入式 (5-6) 的结构性重复读取。

为统一总量口径，记 Task 重建后、核内 spill 插入前的核外 COPY 字节量为 $B_B^{\text{rebuild}}(D)$ ，核内调度引入的增量为 $B_B^{\text{spill}}(D)$ ，则

$$B_B^{\text{add}}(D) = B_B^{\text{rebuild}}(D) - B_0 + B_B^{\text{spill}}(D). \quad (5-7)$$

第一部分反映边界重建和重复读取相对原图的变化，第二部分由核内容量处理产生。选择换出对象不一定产生新的 COPY_OUT：已有有效 DDR 副本时可直接复用，因此 spill 必须按实际插入的读写操作计量 [2]。

容量压力由同时已分配的实例集合决定。即使某个 Task 涉及的累计张量量很大，只要其数据能够依次产生、使用和释放，仍可能满足容量要求；反之，多个尚未释放的输入与新输出同时占用空间，也可能触发换入换出。因此，本文使用式 (5-2) 描述硬约束，以式 (5-7) 及执行时间评价容量处理造成的代价，不以全部潜在复用张量的总和作为可行性条件。

5.3 缓存约束下的多核调度模型

5.3.1 决策变量与共用定义

场景 B 继续采用 $D = (x, \{\pi_k\})$ 。Task、潜在复用关系、跨核通路以及实际执行状态均由该决策派生，没有新增可提交的缓存控制变量。共用方案级条件仍包括完整划分、完整指派、商图无环和同核依赖顺序一致。

场景 B 的执行映射记为

$$\Phi_B(D) = \begin{cases} (\text{mk}_B(D), B_B^{\text{add}}(D), \text{执行统计}), & q_B(D) = 1, \\ \perp, & \text{未取得有效评价结果.} \end{cases} \quad (5-8)$$

相应可行集合为 $\mathcal{D}_{\text{feas}}^B = \{D \in \mathcal{D}_{\text{plan}} : q_B(D) = 1\}$ 。方案级条件相同不意味着不同场景中的全部执行可行性检查相同。

5.3.2 目标函数与评价方式

问题二的目标为

$$\min_{D \in \mathcal{D}_{\text{feas}}^B} \text{mk}_B(D). \quad (5-9)$$

额外搬运量与存储峰值用于说明同核复用和 spill 的影响。候选指派可以利用式 (5-1) 至式 (5-6) 的结构信息，但其时间效果由包含跨核同步和共享带宽的执行评价决定。以字节量为依据构造的启发式偏好，不等于已经证明通信最少的方案执行时间最短。

5.3.3 缓存容量、依赖及其他约束

执行可行性要求全部操作覆盖、真实数据依赖保持、同核同 Pipe 串行、逐事件空间占用不超限，并且全局不存在无法解除的等待。对合并 Task，评估器在核内排布后形成逐 Pipe 顺序及内存复用依赖，再与跨核 COPY 同步关系组合检查全局操作图 [4]。

令展开后的操作图为

$$H_B(D) = (O_B^{\text{exec}}(D), E^{\text{data}} \cup E^{\text{pipe}} \cup E^{\text{mem}} \cup E^{\text{sync}}). \quad (5-10)$$

各边集分别表示真实数据、固定管道顺序、内存空间复用及跨核同步约束。 $H_B(D)$ 无环是执行检查中的必要结构条件，容量约束还需由核内调度和运行状态满足。不能仅检查原始商图，就宣称所有由核内排布新增的等待均已排除。

5.3.4 相对问题一的模型变化与合法性检查

表 5-1 场景 A 与场景 B 的模型差异

维度	场景 A	场景 B
Task 组织	每子图一个独立 Task	每个非空核心一个合并 Task
边界搬运	跨子图均经过 DDR	同核不因子图边界新增搬运
固定等待	同核 Task 切换与跨核前驱完成等待	跨核 COPY 完成后的同步延迟
核内复用范围	单个 Task 内	同核合并 Task 内，受实际容量约束
同核顺序的作用	影响 Task 激活及共享资源时序	还影响核内排布、空间复用及 spill
关键整体查环对象	数据依赖与同核顺序组成的 Task 图	展开操作、Pipe 顺序、内存与跨核依赖组成的操作图

模型变化发生在执行组织和派生成本，而不是提交格式。第四章的候选构造与改进框架可沿用，但评价必须切换到场景 B，并保留相应的执行级检查。

5.4 场景 B 下的求解算法

场景 B 将同一核心上的全部子图合并为一个 Task，同核依赖不因子图边界新增往返搬运，跨核依赖仍需数据传递和同步。因此，同一核心上的分组与次序具有不同于场景 A 的性能作用：V2、V3 虽不改变操作分核，仍可通过影响核内展开顺序改变驻留与流水线组织；V4 则进一步改变哪些生产—消费关系落在同一核心。

本文沿用第四章的方案表示和四阶段求解流程，将场景 B 的评价替换为相应评估环境，不另外设计可由选手控制的 spill 算法。缓存换入换出仍由规定的核内调度流程产生，算法通过切图、分核和同核顺序间接影响其规模。

三问共用同一分层求解框架，差异集中在下表所列接口：

表 5-2 三场景求解接口对照

环节	场景 A	场景 B	场景 B+L2
共用结构	图解析、拓扑凸块构造、分层候选框架	沿用	沿用
候选评价	问题一执行映射	问题二执行映射	含 L2 执行映射
解码代价	跨核通信项（字节代理）	同核关联偏好	分散奖励（多消费者分布）
合法检查	商图 + 增强 Task 图	展开操作图	展开操作图（含 L2）
参数与预算	统一配置	沿用	沿用（新增 λ_s 项）

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.4.1 算法总体思想与选择依据

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.4.2 相对问题一的适配策略

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.4.3 算法流程、伪代码与停止条件

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.4.4 算法复杂度与计算预算

[TODO / 待补] 算法名称及改动内容 TODO；不预设场景 B 方法一定是问题一算法的局部改进。

5.5 实验结果与分析

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.5.1 实验设置与场景对照协议

（实验协议补充稿：以下协议文字待相应数据与日志落位后，方可用”采用””全部通过”等完成性表述。）

场景 B 沿用公共测试集、单核基准和资源记录方式，切换为对应评估入口。场景比较分为固定方案的机制对照与分别求解后的算法系统对照。

固定方案对照保持 `node_to_subgraph` 和 `core_schedules` 相同，分别在 A、B 两入口进行评价，用于观察 Task 合并、同核复用和跨核同步规则的影响。若某份方案未在两个场景都取得有效结果，明确记录其状态，不构造无效比值。

分别求解对照允许各场景使用适配后的求解过程，比较相同预算协议下的最终方案。该结果同时反映硬件规则与算法适配，不解释为单纯的同步机制收益。执行周期降低与额外搬运量变化同时报告，具体原因用逐管道时间线、等待区间和 `spill` 记录分析。

[TODO / 待补] 引用公共设置，补充场景 B 特有配置和对照设计。

5.5.2 1~5 核平均加速比

问题二全部 100 用例的平均加速比为 N2 1.9704、N3 2.7601、N4 3.5509、N5 4.2697（官方评估器口径，与表 4-4 问题二行同源，曲线见图 4-2）。场景 B 的 Task 合并机制消除了同核子图边界的固定等待，使深图的跨核延迟沿关键路累积更慢，各核数下的加速比均高于问题一约 0.15–0.56；逐例结果见附录 B（总额外搬运量列待官方重评导出后补齐）。

5.5.3 Makespan 与总额外数据搬运量

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.5.4 场景 A 与场景 B 对比

平均加速比反映总体质量，但不足以说明时间收益是否伴随搬运变化。为此，选取三类不同表现的离线归档方案，按场景分别优化后的结果并列比较。

表 5-1 两场景分别优化后的典型方案结果（N=5）

用例	场景 A 时间/周期	场景 B 时间/周期	场景 A 额外搬运/字节	场景 B 额外搬运/字节	时间下降
case_005	76,076	46,313	903,202	1,780,852	39.12%
case_008	100,603	63,883	0	0	36.50%
case_009	88,391	82,666	373,724	0	6.48%

case_005 的时间下降 39.12%，额外搬运却增加 97.17%，说明较低搬运量并非较短时间的必要伴随现象。case_008 在两个方案中均无额外搬运，但时间仍有差异，表明还需考察 Task 组织、依赖等待与管道执行。case_009 则同时出现时间下降和额外搬运减少。三类结果体现了时间与搬运之间不同的权衡方式。

表中两列使用的是两个场景分别优化后的方案，因而反映硬件机制与方案变化的共同作用。若要单独估计场景机制收益，应将同一方案在两个场景下交叉评估。资源原因的进一步解释以操作级时间线为依据，不仅凭汇总指标作确定性因果判断。

case_008 的场景 B 五核加速比为 7.6328，大于核数。其单核固定基准为 487,605 周期，五核方案为 63,883 周期。题目允许固定启发式单核基准下出现这种结果；该数字不是相对于最优单核执行时间的超线性证明，也不能直接解释为仅由计算核心增加带来的收益。

5.5.5 缓存复用效果与关键策略消融

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.5.6 求解成本与典型案例

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

5.5.7 算法结果小结

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6 共享 L2 Cache 下的联合优化模型

问题三在场景 B 中增加共享只读 L2。子图划分、核心分配和同核顺序仍是全部可控决策；缓存条目的插入、淘汰及访问命中由固定机制和执行过程共同决定。本章将 L2 表示为执行映射中的状态与带宽服务扩展，而不是新增一个可独立优化的缓存替换策略。

6.1 共享 L2 Cache 机制分析

L2 容量为 1048576 bytes，读带宽为 250 bytes/cycle。COPY_IN 发射时按逻辑张量标识查询缓存；命中访问进入独立的 L2 读带宽池，未命中访问由 DDR 服务。COPY_OUT 等

写回不由只读 L2 提供服务，仍占用 DDR 带宽。两个带宽池相互独立，各自内部的在途搬运公平共享其总带宽 [2,3]。

缓存采用 FIFO 管理：命中不刷新条目顺序；未命中读取完成后进行插入，容量不足时依次淘汰最早插入的条目，直至可以容纳新张量；单张量大于总容量时不缓存。由此，是否命中既取决于逻辑张量是否相同，也取决于此前读取是否已经完成及其条目是否仍驻留。开始读取不能被等同于条目已经进入缓存。

同一时间戳内，完成与缓存更新先于新的就绪操作发射。因此，下文按照事件处理次序定义缓存状态，而不直接用连续时间的左极限代替“发射事件之前”的状态 [2,3]。

6.2 L2 Cache 数据复用模型

6.2.1 共享输入数据与访问关系

记评估器展开后参与缓存查询的 COPY_IN 访问集合为 $\mathcal{A}_Q(D)$ 。对每次访问 j ，记录

$$a_j = (\kappa_j, b_j, s_j, f_j), \quad (6-1)$$

其中 κ_j 为逻辑张量标识， b_j 为访问字节数， s_j 、 f_j 分别为发射和完成时刻。跨核心对同一数据的重复读取及 spill 重载均可能形成同键访问。逻辑张量标识用于识别数据内容，不能因其片上实例编号不同而丢失复用关系。

访问集合与事件时间的来源不同：边界读取由 Task 重建确定，spill 读取由核内调度确定，具体访问的发射和完成时间则由并行执行中的依赖、管道与带宽竞争确定。L2 改变带宽归属后又会影响后续事件时间，因此缓存状态与执行时间需要联合推进。

6.2.2 Cache 命中与数据搬运

记 Q 为 FIFO 队列，包含条目的逻辑标识、大小及插入顺序， $\mathcal{C}$ 为对应驻留键集合。缓存从空状态开始。设 $\mathcal{C}_j^{\text{pre}}$ 为按评估器事件顺序，在第 j 次 COPY_IN 发射事件前的驻留集合，则

$$h_j = \mathbf{1}\{\kappa_j \in \mathcal{C}_j^{\text{pre}}\}. \quad (6-2)$$

这个定义包含相同时间戳内已经先行完成的插入。例如，前一读取在周期 τ 完成并更新缓存，后一读取在同一周期稍后的发射步骤启动，则后者可以观察到该插入。相反，两个读取都在首次加载完成之前发射，不能仅因逻辑键相同就把第二个计为命中。

队列的更新由完成事件触发，并执行固定 FIFO 规则。队列中每个逻辑键只对应一个驻留条目；重复访问不意味着重复占用一份同键缓存空间。缓存状态及两池带宽共同决定后续完成事件，不能只按一个预先给定的访问序列独立计算命中率后再累加时间 [2,3]。

参与查询的读取中，实际由 DDR 与 L2 服务的字节数分别为

$$B_{\text{DDR}}^{\text{Cl}}(D) = \sum_{j \in \mathcal{A}_Q(D)} (1 - h_j) b_j, \quad B_{\text{L2}}^{\text{Cl}}(D) = \sum_{j \in \mathcal{A}_Q(D)} h_j b_j. \quad (6-3)$$

二者之和等于参与查询的读取总字节数。若 $B_{\text{DDR}}^{\text{other}}(D)$ 表示其余由 DDR 服务的核外搬运，包括写回，则

$$B_{\text{DDR}}^{\text{phys}}(D) = B_{\text{DDR}}^{\text{Cl}}(D) + B_{\text{DDR}}^{\text{other}}(D). \quad (6-4)$$

式 (6-4) 与官方额外搬运量 B^{add} 不是同一指标。逻辑 COPY 总量在 Task 重建和核内调度后确定，其中 spill 不是仅由原始静态图结构直接读出的量；后续 L2 模拟改变 COPY 的服务来源，但不删除这些已生成的操作。对于保持同一方案、相同核内展开且仅切换 L2 服务的配对评价，逻辑额外搬运量保持相同，实际 DDR 服务字节量则可以减少。

Cache 字节命中率沿用式 (1-10)。正式结果同时保留访问总字节数和命中字节数，避免把“少量访问中的高比例命中”与“大量读取被分流”混为一谈。

6.2.3 L2 对 DDR 访问需求及带宽竞争的影响

L2 命中把相关读取从 DDR 带宽池分流至独立读带宽池，使 DDR 同期其余搬运可能获得更多带宽。对参与 Cache 查询且仍在传输的 COPY_IN 访问 j ，区间内服务速率按命中状态 h_j 区分：

$$v_j(\tau) = \begin{cases} B_{\text{L2}}/n_{\text{L2}}(\tau), & h_j = 1, \\ B_{\text{DDR}}/n_{\text{DDR}}(\tau), & h_j = 0, \end{cases} \quad (6-5)$$

其中两个 n 分别表示所在带宽池的在途搬运数，仅在相应集合非空时使用该表达。

命中的作用包括更换服务路径和缓解 DDR 竞争，但对最终完成时间的影响取决于这些搬运是否处于关键依赖上，以及分流后两池的动态负载。调度方案改变还可能同时改变并行度、计算均衡和重复读取规模。因此，不能仅根据命中率排序调度方案，也不能把 $b_j/250$ 当作所有命中访问的固定实际时长。

6.3 L2 Cache 条件下的调度优化模型

6.3.1 对问题二模型的扩展

问题三沿用决策 $D = (x, \{\pi_k\})$ 和场景 B 的 Task 组织。执行依赖、核内容量与管道顺序仍须通过对应检查；L2 的容量由插入与淘汰机制处理，不构成“被多个核心共享的全部张量总和必须小于 L2”的静态方案约束。

记含 L2 的有效执行方案集合为 $\mathcal{D}_{\text{feas}}^{B+\text{L2}}$ 。这一记号区分正式评估入口，并不表示新增了自由决策变量。在两入口使用相同核内展开和结构校验的前提下，L2 不增加新的结构约束；但具体方案仍需相应入口验证，不能仅凭场景 B 取得了数值就省略问题三的复评。

6.3.2 目标函数与 L2 感知评价

问题三的优化模型为

$$\min_{D \in \mathcal{D}_{\text{feas}}^{B+L2}} \text{mk}_{B+L2}(D). \quad (6-6)$$

额外搬运量、命中率和实际 DDR 服务流量用于解释结果，不取代时间目标。静态共享特征可用于候选构造，但其实际收益由含 L2 的执行评价检验。

为隔离缓存机制本身的作用，对同一用例、相同核心数量及固定方案 D ，定义

$$S_{N,i}^{\text{Cache}}(D) = \frac{T_{N,i}^B(D)}{T_{N,i}^{B+L2}(D)}. \quad (6-7)$$

该指标只改变缓存服务配置，保持两个方案字段完全相同。若两种配置分别优化，得到 D_B 和 D_{B+L2} ，则对应综合对照为

$$S_{N,i}^{\text{system}} = \frac{T_{N,i}^B(D_B)}{T_{N,i}^{B+L2}(D_{B+L2})}. \quad (6-8)$$

式（6-8）同时包含硬件机制与方案调整的影响，不称为纯缓存增益。两类指标均按逐用例比值求算术平均，不以两组平均加速比之比替代。通过区分固定方案的机制实验与分别优化的系统实验，既能分析只读 L2 的作用，也能评价调度方法对新增资源的利用效果。

6.4 L2 感知调度优化算法

问题三沿用场景 B 的决策对象和 Task 组织，仅在读取路径中增加共享只读 L2。本文不改变容量、带宽或 FIFO 替换规则，而是通过方案所诱导的访问流影响实际缓存行为。

同一逻辑张量的读取能否命中，取决于先前读取的完成与插入时刻、后续发射时刻及期间是否被淘汰。因此，优先级、分核或批次变化都可能影响结果，但不能把启发式分散奖励直接等同于真实 Cache 收益。最终候选仍由完整模拟评价。

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6.4.1 算法思想与选择依据

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6.4.2 调度策略及与问题二的关系

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6.4.3 算法流程、伪代码与停止条件

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6.4.4 算法复杂度与计算预算

[TODO / 待补] 具体策略 TODO，以最终实现为准。

6.5 实验结果与分析

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

6.5.1 实验设置与无 L2 / 有 L2 配对协议

（实验协议补充稿：以下协议文字待相应数据与日志落位后，方可用”采用””全部通过”等完成性表述。）

为区分缓存机制与方案变化，采用两个层次的对照。

同方案机制对照。对每个用例和核数，先按预先说明的规则选取一份在两个配置中均可有效评估的方案 D ，然后分别调用场景 B 和含 L2 的评估入口。两个调用读取完全相同的方案文件，保留其摘要；相对加速比使用式（6-7）。不能仅按“用例名称、核数相同”将两条独立求解记录连接后称为同方案配对。

分别优化的综合对照。分别在无 L2 和含 L2 条件下求解，结果按式（6-8）计算。若希望进一步分析适配的方向，可以对两份方案都执行交叉评价，形成下表，而不必把所有差异强行拆为可加的独立收益。

固定方案	无 L2 评价	含 L2 评价
无 L2 环境所得方案 D_B	$T_B(D_B)$	$T_{B+L2}(D_B)$
含 L2 环境所得方案 D_{B+L2}	$T_B(D_{B+L2})$	$T_{B+L2}(D_{B+L2})$

所有配对比值先逐用例计算，再求算术平均。为区分”硬件收益”与”方案适配收益”，固定含 L2 硬件环境，另定义方案适配收益 $R_{\text{adapt},i} = T_{N,i}^{B+L2}(D_B) / T_{N,i}^{B+L2}(D_{B+L2})$ ——无 L2 环境所得方案 D_B 与含 L2 环境所得方案 D_{B+L2} 在同一 Cache 环境下的执行时间之比；两份方案均取得有效结果时才计算，其全量统计待交叉评价数据落位后补齐。独立均值之比一般不同于比值的均值，不得混称。缓存统计同时记录查询总字节数、命中字节数、次数命中率和字节命中率，报告字段必须直接对应原生结果的含义。

额外搬运量与实际 DDR 流量分别展示。固定方案且核内展开相同时，仅切换 L2 服务不改变已生成的逻辑 COPY 总量；其字节分流可按式（6-3）和式（6-4）分析。若两份独立优化方案的额外搬运量不同，该差异不能只归因于 Cache 命中。

[TODO / 待补] 固定用例、核数和必要的方案标识，区分机制对照与算法对照。

6.5.2 1~5 核下无 L2 与只读 L2 的平均加速比

问题三全部 100 用例的平均加速比为 N2 1.9948、N3 2.7887、N4 3.6367、N5 4.3091（含 L2 配置，与表 4-4 问题三行同源，曲线见图 4-2）。相同核数下，固定方案的无 L2 与只读 L2 对照给出 Cache 相对加速比（式 6-7 口径）的逐例算术平均：N2 1.001、N3 1.007、N4 1.021、N5 1.051（单例最高 2.148）；对应的字节命中率均值为 N2 15.2%、N3 22.0%、N4 24.0%、N5 26.8%（单例最高 77%）。命中率随核数上升源于并发读取共享输入的机会增多；平均 Cache 增益温和（N5 约 5.1%）说明多数用例的瓶颈仍在计算负载与依赖结构，与 6.5.3–6.5.4 的逐例分析一致。

6.5.3 无 L2 与只读 L2 的 Makespan 对比及相对加速比

为区分硬件变化与方案变化，固定问题三方案 D，分别计算

$$R_{\text{Cache}}(D) = \frac{T_{\text{noL2}}(D)}{T_{\text{L2}}(D)}.$$

下表采用更新后的总表中同一问题三记录的 mk_noL2 和 makespan，而非将问题二与问题三的不同方案直接拼接。

表 6-1 同一离线归档方案在两种配置下的性能（N=5）

用例	两配置相同		相对加速比	字节命中率	的额外搬运/字节
	无 L2 时间/周 期	有 L2 时间/周 期			
case_005	45,375	42,227	1.0745	34.99%	1,655,348
case_006	20,378	17,983	1.1332	42.09%	545,788
case_008	63,883	63,883	1.0000	0.00%	0
case_009	69,652	69,144	1.0073	26.85%	881,614
case_011	39,775	39,441	1.0085	33.13%	1,308,672

case_005 和 case_006 的同方案时间分别下降 6.94% 和 11.75%；case_008 未产生缓存命中，其完成时间不变。case_009 和 case_011 虽具有较高的字节命中率，时间下降仍不足 1%。因此，命中率说明读取覆盖程度，不等于关键执行路径上的时间收益。

case_009 还说明了区分两类对照的必要性。该用例问题二归档方案的 Makespan 为 82,666 周期，问题三归档方案为 69,144 周期，两者之比为 1.1956；但固定问题三方案，无 L2 时间已经为 69,652 周期，Cache 单独对应的相对加速比仅为 1.0073。故不能将 19.56% 的端到端加速比增加全部归因于 Cache。

此外，同一方案下的官方逻辑额外搬运量不因缓存命中直接扣减。命中改变读取的数据来源及其进入的带宽池；方案分组与 spill 则影响额外搬运统计。报告中分别保留这两类量，避免将实际 DDR 服务流量和逻辑新增搬运混为一谈。

[TODO / 待补] 【图 6-1 位置：同方案无 L2/Cache 相对加速比分布；图 6-2 位置：字节命中率与相对加速比散点图。标出上述例子，不预设正比例关系。】

6.5.4 Cache 字节命中率与 DDR 数据搬运量

[TODO / 待补] 区分总搬运量、总额外搬运量及其统计口径。

6.5.5 L2 感知策略对比与消融

[TODO / 待补] 区分硬件缓存本身的收益和算法利用缓存的额外效果。

6.5.6 不同计算图的收益差异与机理分析

[TODO / 待补] 结合访问、搬运、等待或调度记录解释受益及不受益的案例；没有相应证据时保留待验证解释。

6.5.7 求解成本与算法结果小结

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

7 模型评价与推广

[TODO / 待补] 内容 TODO：依据题面、最终采用的实现及适用证据补充本节；具体算法、公式和结果尚未填写。

7.1 模型优点

[TODO / 待补] 依据实验、可行性验证及推导，总结三问模型和算法已得到支持的优点。

7.2 模型不足

[TODO / 待补] 说明表现不佳的条件、计算开销、实验覆盖与模型简化带来的限制，以及改进所需证据。

7.3 模型推广

[TODO / 待补] 说明可迁移对象、适用前提和需要重新验证的部分，区分已验证推广与未来设想。

参考文献

- [1] JOUPPI N P, YOUNG C, PATIL N, et al. In-Datcenter Performance Analysis of a Tensor Processing Unit, Proceedings of the 44th Annual International Symposium on Computer Architecture: 1-12, 2017.
- [2] “华为杯”第二十三届中国研究生数学建模竞赛 A 题题面：通用神经网络处理器下的多核调度问题，赛题附件材料（含附录 A—D），2026.
- [3] 多核并行模拟执行算法，赛题附件说明材料，2026.

- [4] 多核调度赛题最终评估代码说明 (README), 赛题附件材料, 2026.
- [5] TOPCUOGLU H, HARIRI S, WU M Y. Performance-effective and low-complexity task scheduling for heterogeneous computing, IEEE Transactions on Parallel and Distributed Systems, 13(3): 260–274, 2002.
- [6] MOREIRA O, POPP M, SCHULZ C. Graph Partitioning with Acyclicity Constraints, Proceedings of the 16th International Symposium on Experimental Algorithms, LIPIcs 75: 30:1–30:15, 2017.
- [7] JEON W, GAGRANI M, BARTAN B, et al. Neural DAG Scheduling via One-Shot Priority Sampling, The Eleventh International Conference on Learning Representations, 2023.
- [8] KOOL W, VANHOOF H, WELLING M. Stochastic Beams and Where to Find Them: The Gumbel-Top- k Trick for Sampling Sequences Without Replacement, Proceedings of the 36th International Conference on Machine Learning, PMLR 97: 3499–3508, 2019.
- [9] WILLIAMS R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning, Machine Learning, 8: 229–256, 1992.

A 问题一逐用例评估结果

表 15 问题一逐用例评估结果 (官方评估器逐例复评; 每格左为 Makespan/cycles, 右为加速比)

用例	N2 mk		sp		N3 mk		sp		N4 mk		sp		N5 mk		sp	
001	116,868	1.9946	78,545	2.9679	58,984	3.9521	47,502	4.9074								
002	140,400	1.8657	107,983	2.4258	77,248	3.3910	60,771	4.3104								
003	501,960	1.1997	492,206	1.2235	487,287	1.2358	471,708	1.2767								
004	199,074	1.9709	134,043	2.9271	104,188	3.7659	88,341	4.4414								
005	85,209	1.1222	80,729	1.1844	78,853	1.2126	78,222	1.2224								
006	40,609	2.0399	31,151	2.6592	27,431	3.0198	27,104	3.0563								
007	507,494	1.9952	338,094	2.9949	258,336	3.9196	203,834	4.9676								
008	244,266	1.9962	163,359	2.9849	123,060	3.9623	100,603	4.8468								
009	94,407	1.6234	88,552	1.7307	91,222	1.6801	89,916	1.7045								
010	45,749	1.9010	31,848	2.7308	24,832	3.5023	26,692	3.2582								
011	92,646	1.9936	69,625	2.6527	46,880	3.9398	46,777	3.9485								
012	29,410	2.0091	21,215	2.7852	16,660	3.5467	15,229	3.8800								
013	132,198	1.9966	88,351	2.9875	67,740	3.8965	55,154	4.7857								
014	16,538,045	1.0702	11,711,104	1.5113	4,550,479	3.8894	3,660,594	4.8349								
015	90,060	1.9694	61,970	2.8621	48,941	3.6240	41,799	4.2432								
016	7,715,523	1.0000	7,715,523	1.0000	5,285,195	1.4598	3,397,411	2.2710								
017	76,239	2.1355	56,448	2.8842	44,166	3.6863	35,540	4.5810								
018	504,530	1.9907	345,861	2.9040	257,782	3.8962	210,148	4.7793								
019	40,804	1.9886	27,872	2.9113	23,934	3.3903	20,408	3.9761								

表 15 问题一逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk	sp	N3 mk	sp	N4 mk	sp	N5 mk	sp
020	266,580	1.9984	177,950	2.9938	133,704	3.9845	107,954	4.9349
021	3,208,870	2.0468	2,095,636	3.1341	1,552,748	4.2299	1,243,902	5.2801
022	29,158	1.9473	19,993	2.8400	15,354	3.6981	12,557	4.5218
023	61,691	1.9876	44,496	2.7556	34,069	3.5990	27,331	4.4863
024	2,555,343	1.0000	2,555,343	1.0000	1,748,975	1.4611	1,124,755	2.2719
025	2,431,840	1.9997	1,623,524	2.9954	1,219,584	3.9874	978,638	4.9692
026	51,350	1.9319	41,563	2.3868	41,529	2.3888	41,611	2.3841
027	1,116,984	2.1164	804,195	2.9395	559,196	4.2274	496,774	4.7586
028	22,359,624	1.9605	15,917,283	2.7540	11,006,263	3.9828	8,926,395	4.9108
029	19,740	1.9025	12,743	2.9471	12,287	3.0565	11,476	3.2725
030	1,411,273	1.9897	946,788	2.9659	711,344	3.9475	578,673	4.8525
031	715,746	1.9761	483,630	2.9245	365,002	3.8750	291,340	4.8547
032	20,644	2.0075	14,725	2.8145	11,906	3.4809	10,210	4.0591
033	888,988	1.9957	605,688	2.9292	459,925	3.8576	369,532	4.8012
034	420,015	2.0071	294,524	2.8622	217,642	3.8733	179,066	4.7077
035	94,892	1.7870	96,142	1.7638	90,615	1.8713	95,455	1.7764
036	466,068	1.9987	311,345	2.9919	233,584	3.9879	187,182	4.9765
037	105,374	1.9929	73,969	2.8390	53,320	3.9385	43,013	4.8823
038	676,424	2.0173	461,122	2.9592	352,248	3.8738	289,861	4.7076
039	721,254	1.9900	485,715	2.9549	407,454	3.5225	315,610	4.5476
040	128,377	1.9743	105,398	2.4047	109,908	2.3061	104,881	2.4166
041	2,984,490	2.0117	2,105,279	2.8519	1,499,728	4.0034	1,223,254	4.9082
042	849,019	1.9867	563,415	2.9938	429,674	3.9256	348,692	4.8373
043	380,375	1.7815	292,418	2.3174	237,963	2.8477	225,465	3.0056
044	99,381	1.5537	101,639	1.5192	110,736	1.3944	132,892	1.1619
045	63,059	1.9920	44,888	2.7984	32,037	3.9209	26,558	4.7298
046	160,984	1.7173	112,092	2.4663	123,678	2.2353	114,951	2.4050
047	318,698	1.0245	310,790	1.0506	307,929	1.0603	305,956	1.0672
048	215,323	1.0320	212,734	1.0446	212,942	1.0436	212,297	1.0467
049	144,934	1.3542	139,954	1.4024	131,875	1.4883	134,375	1.4607
050	95,296	1.5708	90,845	1.6478	91,286	1.6398	89,939	1.6644
051	607,628	1.0000	607,628	1.0000	414,465	1.4661	267,458	2.2719
052	93,421	1.9300	64,791	2.7828	48,846	3.6912	39,731	4.5380
053	739,019	1.9928	491,765	2.9947	472,938	3.1139	450,810	3.2668
054	512,698	1.5897	475,274	1.7149	464,016	1.7565	469,239	1.7370
055	59,578	1.9946	43,225	2.7492	34,300	3.4646	27,082	4.3880
056	246,556	1.1246	242,354	1.1441	236,209	1.1739	232,764	1.1913

表 15 问题一逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		sp		N3 mk		sp		N4 mk		sp		N5 mk		sp	
057	31,423	1.9007	21,283	2.8063	16,971	3.5193	14,053	4.2501								
058	2,210,870	2.0534	1,502,805	3.0208	1,141,180	3.9781	943,156	4.8133								
059	370,362	2.2396	251,009	3.3046	186,084	4.4575	150,782	5.5011								
060	433,063	2.0523	300,109	2.9616	224,924	3.9515	185,435	4.7930								
061	43,745	1.7646	31,774	2.4294	24,321	3.1738	20,200	3.8213								
062	1,577,193	1.8101	1,146,806	2.4894	888,889	3.2117	701,700	4.0684								
063	612,555	1.7474	420,457	2.5458	308,014	3.4752	240,418	4.4522								
064	17,752	1.0768	17,462	1.0947	16,589	1.1523	16,589	1.1523								
065	27,114	1.9572	18,960	2.7989	14,830	3.5784	12,395	4.2814								
066	208,028	1.7261	195,331	1.8383	142,823	2.5141	151,163	2.3754								
067	31,178,978	2.0474	21,073,561	3.0291	16,234,471	3.9321	13,167,883	4.8478								
068	303,344	1.1937	292,049	1.2398	288,055	1.2570	288,672	1.2543								
069	17,583	1.4300	14,647	1.7167	11,496	2.1872	13,115	1.9172								
070	58,827	1.9940	42,714	2.7462	33,390	3.5130	27,260	4.3030								
071	13,023	1.4527	10,325	1.8323	10,758	1.7586	10,555	1.7924								
072	12,002,626	1.9910	8,072,594	2.9604	5,992,722	3.9878	4,879,417	4.8977								
073	4,494,830	2.2429	3,126,575	3.2245	2,468,784	4.0836	2,124,193	4.7461								
074	826,008	2.0366	569,121	2.9559	432,408	3.8904	349,220	4.8171								
075	1,078,232	1.3372	930,849	1.5489	751,436	1.9187	719,790	2.0031								
076	3,072,414	2.0131	2,044,648	3.0250	1,560,099	3.9646	1,290,116	4.7942								
077	257,472	1.9238	180,421	2.7454	130,864	3.7850	108,317	4.5729								
078	1,177,840	1.9495	782,897	2.9329	619,305	3.7076	486,196	4.7227								
079	15,300,680	2.0295	10,110,455	3.0713	7,368,092	4.2144	6,025,063	5.1538								
080	146,133	1.9991	101,509	2.8780	100,060	2.9196	101,212	2.8864								
081	76,860	1.9750	52,790	2.8754	39,588	3.8344	30,943	4.9056								
082	537,830	1.3406	413,643	1.7431	364,876	1.9761	353,798	2.0380								
083	484,071	2.1856	331,942	3.1873	289,800	3.6508	234,944	4.5032								
084	1,255,052	1.9979	836,220	2.9985	628,525	3.9894	503,472	4.9802								
085	2,401,681	1.3274	1,825,946	1.7459	1,555,322	2.0497	1,469,227	2.1698								
086	104,060	1.1378	101,557	1.1659	96,808	1.2231	94,322	1.2553								
087	2,016,614	1.9707	1,428,996	2.7810	1,030,510	3.8564	857,588	4.6340								
088	192,586	1.2650	182,031	1.3384	184,043	1.3237	175,359	1.3893								
089	346,832	1.9984	243,614	2.8450	178,160	3.8903	147,432	4.7011								
090	548,389	2.1488	433,196	2.7202	372,514	3.1633	365,572	3.2233								
091	7,622,228	1.2053	5,547,740	1.6559	2,440,485	3.7643	1,904,885	4.8227								
092	2,426,700	1.9844	1,731,463	2.7812	1,373,480	3.5061	1,167,773	4.1237								
093	37,827	1.9617	25,103	2.9560	19,779	3.7517	15,876	4.6740								

表 15 问题一逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk	sp	N3 mk	sp	N4 mk	sp	N5 mk	sp
094	49,630	1.9120	33,463	2.8357	26,387	3.5962	22,475	4.2221
095	1,042,860	1.9992	695,775	2.9964	524,422	3.9755	420,852	4.9539
096	43,411	1.9395	29,550	2.8492	27,491	3.0626	27,210	3.0942
097	5,156,692	2.2285	3,492,575	3.2903	2,579,804	4.4544	2,097,377	5.4790
098	89,926	1.9731	78,629	2.2565	80,878	2.1938	81,567	2.1753
099	808,940	2.0063	542,966	2.9891	415,365	3.9074	334,879	4.8465
100	75,471	2.0037	54,924	2.7533	55,618	2.7190	55,401	2.7296

B 问题二逐用例评估结果

表 16 问题二逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk	sp	N3 mk	sp	N4 mk	sp	N5 mk	sp
001	116,868	1.9946	78,545	2.9679	58,984	3.9521	47,502	4.9074
002	130,304	2.0103	88,509	2.9595	67,470	3.8824	57,109	4.5868
003	362,596	1.6608	270,878	2.2232	251,876	2.3909	235,418	2.5581
004	199,074	1.9709	134,043	2.9271	104,188	3.7659	88,341	4.4414
005	68,095	1.4042	76,559	1.2489	66,487	1.4381	46,609	2.0515
006	38,913	2.1288	25,105	3.2996	19,411	4.2675	17,796	4.6548
007	507,494	1.9952	338,094	2.9949	255,106	3.9692	203,834	4.9676
008	244,266	1.9962	163,359	2.9849	121,020	4.0291	73,515	6.6327
009	94,373	1.6240	81,995	1.8692	87,711	1.7473	85,035	1.8023
010	42,748	2.0345	29,582	2.9399	22,487	3.8675	17,648	4.9280
011	92,646	1.9936	62,289	2.9652	46,880	3.9398	40,034	4.6135
012	28,763	2.0543	19,856	2.9758	15,624	3.7819	13,159	4.4903
013	132,198	1.9966	88,351	2.9875	66,982	3.9406	53,616	4.9230
014	8,860,566	1.9975	5,989,961	2.9547	4,546,997	3.8924	3,691,924	4.7939
015	67,902	2.6120	53,732	3.3009	47,104	3.7653	38,432	4.6150
016	7,715,523	1.0000	7,715,523	1.0000	2,400,379	3.2143	2,240,577	3.4435
017	74,395	2.1885	49,723	3.2743	39,015	4.1730	25,917	6.2820
018	500,749	2.0057	338,243	2.9694	258,731	3.8819	198,036	5.0716
019	37,224	2.1799	25,986	3.1226	21,108	3.8442	15,787	5.1399
020	266,580	1.9984	177,950	2.9938	133,704	3.9845	107,643	4.9492
021	3,134,777	2.0952	2,144,024	3.0634	1,550,324	4.2365	1,243,141	5.2833
022	28,302	2.0062	19,077	2.9764	14,384	3.9474	11,654	4.8721
023	55,897	2.1936	35,243	3.4791	28,585	4.2895	19,012	6.4493
024	2,555,343	1.0000	2,555,343	1.0000	796,735	3.2073	743,408	3.4373

表 16 问题二逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		sp		N3 mk		sp		N4 mk		sp		N5 mk		sp	
025	2,431,840	1.9997	1,622,742	2.9968	1,218,152	3.9921	974,660	4.9895								
026	44,968	2.2061	33,011	3.0051	41,409	2.3957	27,704	3.5808								
027	1,120,962	2.1089	775,418	3.0486	559,196	4.2274	460,949	5.1284								
028	20,755,981	2.1120	13,752,048	3.1876	10,176,583	4.3075	8,056,841	5.4408								
029	18,890	1.9881	12,743	2.9471	9,822	3.8236	8,382	4.4804								
030	1,404,199	1.9997	946,088	2.9680	709,559	3.9574	562,242	4.9944								
031	715,899	1.9757	477,232	2.9637	359,551	3.9337	284,072	4.9789								
032	19,338	2.1431	13,268	3.1235	9,761	4.2458	10,639	3.8954								
033	882,560	2.0103	599,221	2.9608	444,811	3.9887	352,026	5.0400								
034	421,177	2.0015	265,240	3.1782	211,971	3.9769	157,252	5.3608								
035	91,282	1.8577	87,470	1.9386	85,151	1.9914	80,558	2.1050								
036	466,068	1.9987	311,345	2.9919	233,584	3.9879	187,182	4.9765								
037	105,374	1.9929	71,046	2.9558	53,320	3.9385	43,013	4.8823								
038	679,439	2.0084	454,558	3.0019	341,990	3.9900	274,321	4.9743								
039	708,561	2.0256	479,753	2.9917	389,873	3.6814	327,297	4.3852								
040	125,331	2.0223	100,262	2.5279	100,645	2.5183	89,816	2.8219								
041	2,994,880	2.0047	2,019,234	2.9734	1,518,383	3.9542	1,219,639	4.9227								
042	839,542	2.0091	567,711	2.9711	424,441	3.9740	337,289	5.0009								
043	337,100	2.0103	243,294	2.7853	221,216	3.0633	193,970	3.4936								
044	44,234	3.4907	53,476	2.8874	55,308	2.7918	38,389	4.0222								
045	63,059	1.9920	42,601	2.9486	31,878	3.9405	25,694	4.8888								
046	107,524	2.5711	81,236	3.4031	75,999	3.6376	85,945	3.2167								
047	308,421	1.0586	300,849	1.0853	284,318	1.1484	204,745	1.5947								
048	209,876	1.0588	201,615	1.1022	180,008	1.2345	143,991	1.5433								
049	123,205	1.5931	101,494	1.9339	81,842	2.3982	80,964	2.4242								
050	81,862	1.8286	82,025	1.8249	75,131	1.9924	59,312	2.5238								
051	591,329	1.0276	599,752	1.0131	191,111	3.1795	178,064	3.4124								
052	86,285	2.0896	58,626	3.0754	43,557	4.1394	32,862	5.4866								
053	716,642	2.0550	501,587	2.9361	430,105	3.4240	399,561	3.6858								
054	477,017	1.7086	347,915	2.3427	305,396	2.6688	280,680	2.9038								
055	59,068	2.0118	37,794	3.1443	30,675	3.8740	21,067	5.6408								
056	177,620	1.5611	139,853	1.9827	129,923	2.1342	128,740	2.1538								
057	29,633	2.0155	19,913	2.9993	16,155	3.6971	12,825	4.6570								
058	2,276,675	1.9940	1,526,307	2.9743	1,142,054	3.9750	941,768	4.8204								
059	369,318	2.2460	266,217	3.1158	185,216	4.4784	150,782	5.5011								
060	430,966	2.0623	286,518	3.1020	222,571	3.9933	167,053	5.3204								
061	39,472	1.9556	26,034	2.9650	20,506	3.7643	20,283	3.8057								

表 16 问题二逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		sp		N3 mk		sp		N4 mk		sp		N5 mk		sp	
062	1,430,406	1.9958	959,975	2.9738	720,299	3.9634	587,612	4.8583								
063	536,176	1.9964	364,643	2.9355	275,826	3.8807	232,682	4.6003								
064	16,073	1.1893	15,358	1.2447	14,838	1.2883	14,916	1.2816								
065	26,162	2.0284	17,980	2.9515	10,482	5.0628	11,492	4.6178								
066	198,967	1.8047	147,872	2.4282	132,561	2.7087	125,218	2.8676								
067	30,774,616	2.0743	20,344,683	3.1377	15,291,745	4.1745	12,588,983	5.0707								
068	231,855	1.5617	189,309	1.9127	176,641	2.0499	167,859	2.1571								
069	12,924	1.9455	10,456	2.4047	9,739	2.5818	9,452	2.6602								
070	55,274	2.1222	39,052	3.0037	25,343	4.6285	24,656	4.7575								
071	11,002	1.7196	8,054	2.3490	8,056	2.3484	7,992	2.3672								
072	12,000,814	1.9914	8,095,542	2.9520	6,111,520	3.9103	5,008,397	4.7716								
073	4,247,219	2.3737	2,863,798	3.5204	2,231,456	4.5180	1,854,429	5.4365								
074	824,170	2.0411	564,181	2.9817	432,209	3.8922	335,984	5.0069								
075	797,963	1.8069	587,561	2.4539	458,459	3.1449	427,591	3.3719								
076	3,090,756	2.0012	2,060,836	3.0013	1,564,870	3.9525	1,295,047	4.7760								
077	254,503	1.9462	166,522	2.9745	126,643	3.9112	109,519	4.5227								
078	1,029,560	2.2302	766,642	2.9951	524,644	4.3766	497,039	4.6196								
079	15,262,715	2.0345	10,021,825	3.0985	7,486,164	4.1480	6,074,711	5.1117								
080	145,224	2.0116	97,925	2.9833	86,546	3.3755	93,299	3.1312								
081	76,061	1.9957	51,654	2.9387	39,588	3.8344	30,943	4.9056								
082	385,462	1.8706	272,420	2.6468	238,383	3.0247	209,247	3.4459								
083	422,492	2.5042	291,169	3.6336	214,624	4.9295	200,760	5.2699								
084	1,254,650	1.9985	835,164	3.0023	627,384	3.9966	378,550	6.6237								
085	1,852,196	1.7211	1,266,639	2.5168	1,013,148	3.1465	848,638	3.7565								
086	74,661	1.5859	92,425	1.2811	89,250	1.3266	60,321	1.9629								
087	2,153,189	1.8457	1,348,144	2.9478	1,046,046	3.7991	853,863	4.6542								
088	155,548	1.5662	129,778	1.8772	121,099	2.0118	104,021	2.3421								
089	299,270	2.3159	208,395	3.3259	152,132	4.5559	123,062	5.6321								
090	453,562	2.5980	329,841	3.5725	294,367	4.0030	291,270	4.0456								
091	4,602,186	1.9962	3,147,282	2.9190	2,495,441	3.6814	1,861,058	4.9363								
092	2,041,876	2.3584	1,346,651	3.5759	1,008,098	4.7769	806,778	5.9689								
093	37,827	1.9617	25,103	2.9560	19,779	3.7517	15,876	4.6740								
094	36,518	2.5985	30,169	3.1453	24,154	3.9286	19,895	4.7696								
095	1,040,850	2.0030	693,735	3.0053	523,207	3.9848	420,749	4.9551								
096	37,908	2.2210	28,469	2.9574	27,057	3.1117	26,291	3.2024								
097	5,617,602	2.0456	3,660,459	3.1394	2,626,908	4.3745	2,102,348	5.4660								
098	88,555	2.0036	69,123	2.5669	52,453	3.3826	52,668	3.3688								

表 16 问题二逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		N3 mk		N4 mk		N5 mk	
		sp		sp		sp		sp
099	807,584	2.0097	543,655	2.9853	406,776	3.9899	328,079	4.9470
100	74,356	2.0338	52,485	2.8813	40,516	3.7324	48,661	3.1077

C 问题三逐用例评估结果

表 17 问题三逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		N3 mk		N4 mk		N5 mk	
		sp		sp		sp		sp
001	116,868	1.9946	78,545	2.9679	58,984	3.9521	47,502	4.9074
002	130,025	2.0146	88,509	2.9595	67,470	3.8824	53,799	4.8690
003	362,482	1.6614	268,432	2.2434	241,470	2.4939	221,826	2.7148
004	196,032	2.0015	131,412	2.9857	104,188	3.7659	88,341	4.4414
005	68,095	1.4042	76,565	1.2488	67,585	1.4148	42,227	2.2644
006	38,913	2.1288	24,798	3.3405	20,059	4.1297	17,685	4.6840
007	507,494	1.9952	338,094	2.9949	254,398	3.9802	203,834	4.9676
008	136,244	3.5789	110,229	4.4236	104,264	4.6766	95,353	5.1137
009	94,373	1.6240	83,448	1.8366	86,960	1.7624	69,415	2.2079
010	42,748	2.0345	29,582	2.9399	22,577	3.8521	17,861	4.8692
011	92,646	1.9936	62,289	2.9652	46,880	3.9398	39,877	4.6317
012	27,871	2.1201	18,527	3.1893	11,916	4.9587	11,868	4.9788
013	132,198	1.9966	88,351	2.9875	66,982	3.9406	54,117	4.8774
014	8,852,007	1.9994	5,982,671	2.9583	4,537,470	3.9005	3,678,921	4.8108
015	66,104	2.6831	49,598	3.5760	35,697	4.9685	38,126	4.6520
016	7,715,523	1.0000	7,715,523	1.0000	2,400,379	3.2143	2,240,577	3.4435
017	72,003	2.2612	49,177	3.3107	36,423	4.4700	33,345	4.8826
018	497,643	2.0182	331,431	3.0304	248,233	4.0461	199,472	5.0351
019	36,428	2.2275	25,986	3.1226	21,108	3.8442	16,310	4.9751
020	266,580	1.9984	177,950	2.9938	133,704	3.9845	107,650	4.9489
021	3,134,101	2.0956	2,142,171	3.0660	1,550,324	4.2365	1,249,380	5.2570
022	28,302	2.0062	18,803	3.0197	14,384	3.9474	11,694	4.8555
023	47,907	2.5594	34,328	3.5718	25,796	4.7532	23,240	5.2760
024	2,555,343	1.0000	2,555,343	1.0000	796,735	3.2073	743,408	3.4373
025	2,431,840	1.9997	1,622,742	2.9968	1,218,152	3.9921	975,282	4.9863
026	44,343	2.2372	33,065	3.0002	34,670	2.8613	26,861	3.6932
027	1,120,962	2.1089	806,498	2.9311	559,196	4.2274	460,949	5.1284
028	20,748,327	2.1128	13,752,048	3.1876	10,176,567	4.3075	8,049,671	5.4457
029	18,924	1.9845	12,743	2.9471	9,822	3.8236	8,238	4.5588

表 17 问题三逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		sp		N3 mk		sp		N4 mk		sp		N5 mk		sp	
030	1,409,232	1.9926	944,631	2.9726	696,813	4.0298	562,180	4.9949								
031	715,411	1.9770	477,082	2.9646	359,067	3.9390	293,041	4.8265								
032	19,338	2.1431	13,216	3.1358	9,817	4.2216	10,370	3.9964								
033	888,048	1.9979	594,409	2.9848	443,847	3.9973	354,075	5.0108								
034	417,727	2.0181	277,088	3.0423	208,623	4.0408	171,673	4.9105								
035	91,282	1.8577	94,319	1.7978	85,757	1.9773	76,786	2.2084								
036	466,068	1.9987	311,345	2.9919	233,584	3.9879	187,182	4.9765								
037	105,374	1.9929	70,729	2.9691	53,320	3.9385	43,013	4.8823								
038	675,236	2.0209	450,319	3.0302	340,734	4.0048	272,527	5.0070								
039	705,615	2.0341	478,298	3.0008	368,055	3.8996	293,525	4.8897								
040	125,331	2.0223	112,056	2.2619	107,762	2.3520	98,093	2.5838								
041	2,990,762	2.0075	2,013,306	2.9821	1,512,623	3.9692	1,211,069	4.9576								
042	835,959	2.0177	565,113	2.9848	421,559	4.0012	341,698	4.9363								
043	340,895	1.9879	245,509	2.7602	232,022	2.9207	208,813	3.2453								
044	44,185	3.4946	50,128	3.0803	30,216	5.1101	35,173	4.3899								
045	63,059	1.9920	42,304	2.9693	31,878	3.9405	25,867	4.8561								
046	107,524	2.5711	81,236	3.4031	71,257	3.8797	63,424	4.3588								
047	295,934	1.1033	287,059	1.1374	269,712	1.2106	193,167	1.6903								
048	199,793	1.1123	199,808	1.1122	172,736	1.2865	139,917	1.5882								
049	123,190	1.5933	101,324	1.9371	81,432	2.4103	79,765	2.4607								
050	89,712	1.6686	80,752	1.8537	78,208	1.9140	58,949	2.5393								
051	582,906	1.0424	599,752	1.0131	188,440	3.2245	178,061	3.4125								
052	86,227	2.0910	55,724	3.2356	42,904	4.2024	34,629	5.2066								
053	713,925	2.0628	495,853	2.9700	418,472	3.5192	374,425	3.9332								
054	452,546	1.8010	347,319	2.3467	303,617	2.6845	273,282	2.9825								
055	52,315	2.2715	37,752	3.1478	30,624	3.8805	23,642	5.0264								
056	177,457	1.5625	139,698	1.9849	128,944	2.1504	127,092	2.1818								
057	29,633	2.0155	20,047	2.9793	16,155	3.6971	12,877	4.6382								
058	2,270,206	1.9997	1,526,307	2.9743	1,141,573	3.9767	937,354	4.8431								
059	369,318	2.2460	259,177	3.2004	185,216	4.4784	150,736	5.5028								
060	430,940	2.0624	286,283	3.1046	216,166	4.1116	178,271	4.9856								
061	36,960	2.0885	26,055	2.9626	19,777	3.9031	16,276	4.7426								
062	1,430,406	1.9958	1,037,183	2.7525	720,299	3.9634	587,612	4.8583								
063	536,176	1.9964	372,791	2.8713	275,826	3.8807	231,697	4.6198								
064	16,073	1.1893	15,358	1.2447	14,839	1.2882	14,842	1.2880								
065	25,531	2.0786	17,767	2.9869	12,814	4.1414	11,413	4.6498								
066	195,572	1.8360	144,554	2.4840	133,038	2.6990	126,663	2.8348								

表 17 问题三逐用例评估结果（官方评估器逐例复评；每格左为 Makespan/cycles，右为加速比）

用例	N2 mk		sp	N3 mk		sp	N4 mk		sp	N5 mk		sp
067	30,739,330		2.0766	20,270,656		3.1491	15,188,338		4.2029	12,554,416		5.0847
068	231,721		1.5626	187,794		1.9282	172,644		2.0974	157,383		2.3007
069	12,950		1.9416	10,985		2.2889	9,715		2.5882	8,767		2.8680
070	55,274		2.1222	39,052		3.0037	26,523		4.4226	22,568		5.1976
071	10,454		1.8097	8,002		2.3643	7,969		2.3741	7,904		2.3936
072	11,977,996		1.9951	8,095,552		2.9520	6,100,247		3.9175	4,826,790		4.9511
073	4,202,559		2.3989	2,863,798		3.5204	2,130,819		4.7313	1,768,210		5.7016
074	844,814		1.9913	555,851		3.0264	420,761		3.9981	334,863		5.0237
075	797,960		1.8069	587,430		2.4544	458,179		3.1468	421,997		3.4166
076	3,087,898		2.0030	2,056,401		3.0077	1,541,918		4.0113	1,243,489		4.9740
077	244,401		2.0267	168,429		2.9408	131,875		3.7560	108,743		4.5550
078	1,029,560		2.2302	735,967		3.1199	524,644		4.3766	460,816		4.9828
079	15,262,444		2.0346	10,019,984		3.0990	7,486,178		4.1479	6,074,334		5.1120
080	145,224		2.0116	97,925		2.9833	81,477		3.5855	72,044		4.0550
081	76,044		1.9961	50,855		2.9849	38,772		3.9151	30,943		4.9056
082	385,307		1.8713	272,384		2.6471	238,254		3.0264	205,915		3.5016
083	422,492		2.5042	291,169		3.6336	214,624		4.9295	198,206		5.3378
084	1,252,352		2.0022	835,164		3.0023	627,384		3.9966	378,550		6.6237
085	1,848,816		1.7243	1,266,498		2.5171	1,010,632		3.1544	834,161		3.8217
086	74,578		1.5876	93,205		1.2704	88,575		1.3368	53,159		2.2273
087	2,102,473		1.8902	1,370,065		2.9006	1,103,037		3.6028	840,428		4.7286
088	154,759		1.5742	126,786		1.9215	114,292		2.1316	101,815		2.3928
089	299,270		2.3159	208,395		3.3259	152,132		4.5559	123,062		5.6321
090	453,562		2.5980	317,353		3.7131	255,530		4.6114	247,585		4.7594
091	4,594,124		1.9997	3,032,426		3.0295	2,290,943		4.0100	1,858,021		4.9444
092	2,037,340		2.3636	1,347,978		3.5724	1,005,699		4.7883	804,952		5.9824
093	37,326		1.9880	25,103		2.9560	19,207		3.8634	15,876		4.6740
094	45,899		2.0674	30,169		3.1453	24,154		3.9286	19,895		4.7696
095	1,040,850		2.0030	693,735		3.0053	523,207		3.9848	420,749		4.9551
096	40,084		2.1004	27,208		3.0945	27,057		3.1117	25,159		3.3465
097	5,617,602		2.0456	3,660,338		3.1395	2,626,908		4.3745	2,102,250		5.4663
098	88,555		2.0036	62,487		2.8395	47,105		3.7667	44,297		4.0055
099	806,707		2.0119	537,310		3.0206	404,180		4.0155	326,552		4.9701
100	74,356		2.0338	52,467		2.8822	39,365		3.8416	45,611		3.3155

D 补充推导

以下命题针对本文定义的图表示及题设执行机制给出，不将其列为已有算法效果或实验发现。

D.1 拓扑连续区间划分的充分性

命题 D.1. 给定操作 DAG 的一个拓扑序 $v_1, \dots, v_n$ ，将该序列划分为互不重叠的连续区间，每个区间构成一个子图，则所得商图无环。

证明。 将区间依次编号为 $1, \dots, K$ 。若存在跨区间依赖 $u \rightarrow v$ ，拓扑序保证 u 的位置早于 v ；连续区间划分进一步保证 u 所在区间编号小于 v 所在区间编号。因此，所有商图边都从较小编号指向较大编号，不可能构成有向环。证毕。

该命题只证明商图无环。若再按区间编号递增的顺序安排每个核心上的子图，则场景 A 的顺序边也从较小编号指向较大编号，故增强图同样无环；完整执行可行性仍须检查容量和展开后的执行约束。

非必要性。 连续区间是保证无环的构造条件，不是一般合法划分的必要条件。考虑依赖 $a \rightarrow b, a \rightarrow c$ 及拓扑序 (a, b, c) ，划分为 $\{a, c\}$ 与 $\{b\}$ 。前一分组不是该拓扑序的连续区间，但商图仅有 $\{a, c\} \rightarrow \{b\}$ ，仍无环。因此，不能写成“全局排名相邻且同核，当且仅当商图无环”。“同核”是满足某一合并操作语义的附加条件，也不是商图无环性的定义。

D.2 场景 A 的机制下界

计算负载下界。 设某个计算管道 p 的总工作量为 W_p 。在 N 个核心上，至少一个核心承担不少于 W_p/N 的该管道负载；同核同管道不能重叠执行，故总完成时间至少为 W_p/N 。分别对 M, V 取最大，得到 L_{load} 。

带宽下界。 场景 A 的全部核外搬运由同一 DDR 带宽池服务，总需求为 $B_0 + B_A^{\text{add}}(D)$ 。内部服务时间任意区间的聚合速率不超过 B_{DDR} ，故

$$B_0 + B_A^{\text{add}}(D) \leq B_{\text{DDR}} \text{mk}_A(D), \quad (\text{D-1})$$

由此得到 $L_{\text{bw}}(D)$ 。最终完成时间向整数周期取整不会削弱该下界。

依赖链下界。 对商图任意路径 $s_1 \rightarrow \dots \rightarrow s_r$ ，后继 Task 不能在依赖前驱 Task 完成前激活。每个 Task 至少执行 $\max\{W_M^{(s_i)}, W_V^{(s_i)}\}$ 个周期的计算工作；相邻依赖 Task 在不同核心时至少增加 1000 cycles 等待，在同核时至少受一次 100 cycles 的 Task 切换约束。因此，该链总耗时不少于式 (4-15) 中的相应和式。对所有路径取最大得到 $L_{\text{relay}}(D)$ 。

三条条件同时成立，但可以在实际时间线上重叠发生，故联合下界取三者的最大值，而不是三者之和。

D.3 方案诊断与全局最优值的区别

式 (4-16) 中的搬运量和依赖链取决于方案。不能由 $\text{mk}_A(D)$ 接近 $L_A(D)$ 推断它接近全局最优。

例如，一个方案因为分组较碎而产生大量边界 COPY，即使它几乎充分利用 DDR，仍可能被减少边界的另一方案显著改进。前者接近自身带宽下界，只说明其现有需求难以通过单纯重排进一步隐藏，不说明这些需求不可减少。

与方案无关的 $L_0(G, N)$ 才可以给出统一的最优值参照。另记某个已验证历史方案为 D_{ref} ，则

$$L_0(G, N) \leq \text{mk}_A^* \leq \text{mk}_A(D_{\text{ref}}). \quad (\text{D-2})$$

因此，已知可行解的 Makespan 是最小化问题最优值的上界；它对应的加速比则不是全局最优加速比的上界。“历史最好”“池内最好”和“全局最优”必须分别使用。